

Pengembangan Pipeline Konstruksi Basis Pengetahuan pada Sistem OMNI-RAG Multi-Domain Berbasis Plugin pada Studi Kasus Peraturan Perundang-undangan dan User Manual

Moh Fairuz Alauddin Yahya | 13522057 | Program Studi Informatika, Institut Teknologi Bandung

ABSTRAK

Retrieval-Augmented Generation (RAG) bergantung pada basis pengetahuan yang mampu menemukan bukti relevan sebelum model bahasa menyusun jawaban. Tantangan ini semakin besar pada sistem multi-domain karena peraturan perundang-undangan bidang pendidikan di Indonesia dan manual pengguna produk Netgear memiliki hierarki, istilah, dan kebutuhan pencarian yang berbeda. Pemotongan yang mengabaikan struktur dapat memutus konteks atau menghilangkan identitas sumber, sedangkan logika pengindeksan dan pembentukan relasi yang terlalu khusus sulit diperluas.

Penelitian ini mengembangkan dan mengevaluasi pipeline konstruksi basis pengetahuan berbasis plugin untuk OMNI-RAG. Artefak kanonik dan kontrak kompatibilitas yang sama memisahkan orkestrator dari empat strategi chunker, tiga strategi indexer, dan dua strategi knowledge graph, yaitu legal graph deterministik dan LLM graph. Chunk kanonik yang sama diproyeksikan menjadi indeks sparse, dense, atau hybrid serta menjadi legal graph opsional; profile, manifest, dan provenance mencatat pemilihan komponen dan menjaga keterlacakan. Eksperimen menggunakan sembilan manual Netgear (1.400 halaman; 200 baris pertanyaan bilingual dari 100 slot) dan korpus hukum berisi 256 dokumen dengan 25 pertanyaan terverifikasi, yang terdiri atas 49 dokumen referensi dan 207 dokumen noise terpilih secara stratified. Retrieval diukur pada $K=30$ dengan sweep $K=5-60$, sedangkan generation menggunakan sepuluh evidence teratas.

Pada korpus manual, structure-aware hybrid mencapai Recall@30 sebesar 0,740 pada kelompok chunker, sedangkan structure-aware dense mencapai 0,785 pada kelompok indexer; skor correctness/faithfulness generation masing-masing adalah 0,788/0,958. Pada korpus hukum, legal-structure dense mencapai Recall@30 sebesar 0,6854 dan skor generation 0,690/0,972, sementara hybrid memperoleh MRR tertinggi sebesar 0,5439. Traversal legal graph hingga kedalaman dua mencapai neighborhood recall maksimum 1,000, tetapi metrik ini dibaca terpisah dari context-reference recall. Hasil menunjukkan bahwa pemeliharaan struktur dan pencocokan semantik meningkatkan cakupan evidence, sedangkan konfigurasi terbaik bergantung pada domain dan metrik yang diprioritaskan.

Kata kunci: OMNI-RAG, Retrieval-Augmented Generation, konstruksi basis pengetahuan, chunking, indexing, knowledge graph, arsitektur plugin.