




Pengembangan Pipeline Konstruksi Basis Pengetahuan pada Sistem OMNI-RAG Multi-Domain Berbasis Plugin pada Studi Kasus Peraturan Perundang-undangan dan User Manual

Pipeline konstruksi basis pengetahuan · evaluasi lintas domain

Moh Fairuz Alauddin Yahya | 13522057 | Teknik Informatika | Institut Teknologi Bandung

Pembimbing: Dr. Agung Dewandaru, S.T., M.Sc. · I Wayan Gunada, S.H., M.H.

RESEARCH STORY

Bagaimana satu sistem RAG dapat beradaptasi terhadap struktur dokumen yang berbeda tanpa mengubah jalur inti?

JAWABAN SINGKAT

Representasi kanonik + kontrak plugin memungkinkan strategi chunking, indexing, dan knowledge graph dibandingkan sebagai faktor yang terpisah.

01 Masalah

Dokumen hukum dan manual produk menyimpan makna dalam struktur yang berbeda. Jika unit retrieval dipotong tanpa struktur, konteks yang dibutuhkan dapat tercerai; jika strategi dibuat spesifik di jalur inti, sistem sulit diperluas.

PERATURAN USER MANUAL

hierarki Pasal / Ayat vs. heading / prosedur / tabel

02 Tujuan penelitian


Membangun pipeline konstruksi basis pengetahuan yang dapat mengganti strategi per domain, lalu mengukur dampaknya dengan protokol one factor at a time (OFAT).

satu format artefak banyak strategi

Perubahan komponen tidak memaksa perubahan orkestrator.

03 Pendekatan modular

Dokumen diproses sekali menjadi artefak kanonik. Strategi yang dipilih kemudian membentuk proyeksi retrieval dan relasi antardokumen; downstream menerima bentuk data yang sama.



Plugin = unit of strategy replacement; canonical artifacts = boundary of comparison.

04 Bagaimana diuji?

Eksperimen memakai OFAT: satu komponen berubah, sedangkan corpus, parser, embedding, cutoff, dan tahap hilir dipertahankan.

KORPUS

9 manual Netgear

1.400 halaman · 200 pertanyaan bilingual

256 dokumen hukum

25 pertanyaan terverifikasi

FAKTOR UJI

Chunker

sliding · recursive · structure-aware

Indexer

sparse · dense · hybrid

Knowledge graph

17 relasi berarah · 24 tak berarah

METRIK & KONTROL

K = 30

sweep 5-60; generation K = 10

Recall utama

Precision · MRR · NDCG


Generation

correctness · faithfulness

05 Bukti eksperimental

Pada K = 30, perbedaan paling jelas muncul pada cakupan retrieval. Tidak ada satu konfigurasi yang terbaik untuk semua metrik; domain dan tujuan tahap menentukan pilihan.


Chunker · manual



Indexer · manual



Indexer · hukum



What changes downstream?

0.788

manual correctness

0.958

manual faithfulness

0.690

legal correctness

0.972

legal faithfulness

Legal graph · neighborhood recall



Graph expands document neighborhood; separate from context-reference recall.

06 Temuan utama

01 Struktur menjaga cakupan

Structure-aware chunking mengungguli fixed-window pada dua domain yang diuji.

02 Dense menjaga coverage

Dense memberi Recall@30 tertinggi pada manual dan korpus hukum; hybrid unggul pada MRR hukum.

03 Modularitas membuatnya dapat diuji

Artefak kanonik dan kontrak plugin mengisolasi perubahan komponen tanpa menulis ulang jalur inti.

Konfigurasi terbaik bersifat kondisional: pilih komponen sesuai struktur domain dan metrik tahap yang diprioritaskan.