

Konstruksi Basis Pengetahuan Berbasis *Plugin* pada Omni-RAG: Peraturan Perundang-Undangan dan *User Manual*

Moh Fairuz Alauddin Yahya

Program Studi Informatika, Institut Teknologi Bandung

Abstrak

Dokumen dengan struktur berbeda membutuhkan cara pemotongan dan pencarian yang berbeda pula. Pada sistem *Retrieval-Augmented Generation* (RAG), pemotongan yang mengabaikan struktur dapat menghilangkan konteks, sedangkan komponen yang terikat pada satu *domain* menyulitkan penambahan sumber baru. Penelitian ini mengembangkan *pipeline* konstruksi basis pengetahuan pada Omni-RAG melalui tiga komponen berbasis *plugin*, yaitu *chunker*, *indexer*, dan pembangun *knowledge graph*. Kontrak *canonical artifact* menjaga identitas dan keterlacakan sumber ketika strategi diganti. Evaluasi *retrieval-only* menggunakan sembilan *User Manual* Netgear dengan 1.400 halaman dan 200 pertanyaan dualbahasa, serta 255 peraturan perundang-undangan bidang pendidikan di Indonesia dengan 100 pertanyaan. Pada perbandingan *chunker* dengan $K = 25$, strategi *structure-aware* mencapai *recall* 0,740 untuk *User Manual* dan 0,64 untuk peraturan. Pada perbandingan konfigurasi dalam setiap korpus, *dense retrieval* mencapai 0,835 pada $K = 45$ untuk *User Manual*, sedangkan *hybrid retrieval* mencapai 0,67 pada $K = 25$ untuk peraturan. Pada 30 pertanyaan relasi hukum, *sparse retrieval* menghasilkan *KG recall* tertinggi, yaitu 0,517 pada $K = 25$. Hasil ini mendukung pemilihan strategi sesuai struktur dokumen dan kebutuhan pencarian. Evaluasi belum mengukur kualitas jawaban akhir atau generalisasi ke korpus lain.

Kata kunci: Omni-RAG, *plugin*, *chunking*, *retrieval*, *knowledge graph*.

1 Pendahuluan

Informasi yang diperlukan pengguna sering tersedia dalam dokumen, tetapi tersebar di beberapa bagian dengan istilah dan struktur yang berbeda. RAG mengambil informasi dari sumber eksternal sebelum model bahasa membentuk jawaban [1]. Keberhasilan tahap ini bergantung pada bagaimana dokumen diubah menjadi unit informasi yang dapat ditemukan kembali.

Peraturan perundang-undangan dan *User Manual* memperlihatkan dua kebutuhan yang berbeda. Pasal merupakan unit struktural utama dalam representasi dokumen hukum. Pemahaman pada tingkat pasal memerlukan rincian di bawahnya, yaitu ayat, huruf, dan angka. Sementara itu, petunjuk produk tersusun atas bagian, subbagian, dan langkah prosedur. Pemotongan berdasarkan panjang teks saja dapat memisahkan rincian dari konteks yang menjelaskannya.

Strategi pencarian juga perlu disesuaikan. *Sparse retrieval* memanfaatkan kecocokan istilah, sedangkan *dense retrieval* menggunakan representasi vektor untuk menemukan kedekatan makna [2, 3]. Performa pada satu koleksi belum tentu berlaku pada koleksi lain, sebagaimana menjadi perhatian dalam evaluasi lintas *domain* [4]. Relasi antarperaturan menambah kebutuhan untuk mempertahankan hubungan yang tidak cukup direpresentasikan sebagai potongan teks terpisah.

Penelitian ini mengembangkan *pipeline* konstruksi basis pengetahuan berbasis *plugin* pada Omni-RAG. Kontribusinya mencakup pembentukan *chunk* dengan identitas sumber, penyediaan strategi *sparse*, *dense*, dan *hybrid*, serta pembentukan *knowledge graph* dari *chunk* yang sama. Ketiganya memakai kontrak yang memungkinkan peng-

gantian strategi tanpa mengubah orkestrator inti. Evaluasi membandingkan konfigurasi pada dua korpus untuk menilai kemampuan menemukan kembali sumber yang relevan.

Context PII, *guardrail*, dan *history compactor* dibahas sebagai komponen pendukung percakapan. Kontribusi komponen tersebut tidak diukur dalam eksperimen. Akuisisi dokumen, *parser*, dan pembentukan jawaban menjadi konteks integrasi sistem, sedangkan fokus artikel ini adalah konstruksi basis pengetahuan dan hasil *retrieval*.

2 Metode dan Rancangan Sistem

2.1 Kontrak dan Alur Pemrosesan

Konstruksi basis pengetahuan mencakup tiga tahap, yaitu membagi representasi dokumen menjadi unit yang lebih kecil, membentuk indeks pencarian, dan membentuk entitas serta relasi dalam *knowledge graph*. *Parser* menyediakan *CanonicalDocument* sebagai masukan yang memuat teks dan struktur dokumen. *Chunker* menghasilkan *CanonicalChunks*, lalu *indexer* dan pembangun graf mengolahnya menjadi *CanonicalIndex* dan *CanonicalGraph*.

Setiap *artifact* mempertahankan identitas dokumen, posisi sumber, *metadata*, dan *provenance*. Karena indeks dan

Tabel 1: Kontrak utama konstruksi basis pengetahuan.

Komponen	Masukan dan keluaran
<i>Chunker</i>	<i>CanonicalDocument</i> menjadi <i>CanonicalChunks</i>
<i>Indexer</i>	<i>CanonicalChunks</i> menjadi <i>CanonicalIndex</i>
<i>Knowledge graph</i>	<i>CanonicalChunks</i> menjadi <i>CanonicalGraph</i>

graf berasal dari kumpulan *chunk* yang sama, hasil pencarian dapat dipetakan kembali ke sumber tanpa pemotongan ulang. Identitas ini juga menjadi dasar pencocokan hasil *retrieval* dengan *context reference* dalam evaluasi.

Pengguna menentukan sumber data dan komponen melalui *profile*. *Manifest* mendeskripsikan identitas, versi, konfigurasi, dan kapabilitas *plugin*. Pemeriksaan kompatibilitas menjaga agar komponen yang dipilih memenuhi kontrak masukan dan keluaran. Penambahan strategi dilakukan melalui *adapter*. Jaminan perluasan ini terbatas pada logika komponen yang sesuai kontrak. Perubahan infrastruktur atau integrasi eksternal tetap dapat memerlukan perubahan kode inti.

2.2 Pembentukan Unit Informasi

Structure-aware chunker menggunakan batas struktur dokumen untuk menentukan unit informasi. Pada *User Manual*, *block* teks tetap membawa *parent context* sehingga bagian yang berisi prosedur dapat dibaca bersama judul atau konteks induknya. Pada peraturan, *legal structure-aware chunker* mempertahankan batas pasal dan ayat serta pemetaan ke identitas unit sumber.

Sebagai pembanding, *recursive chunker* membagi teks menggunakan pemisah bertingkat, sedangkan *sliding-window chunker* menggunakan jendela dengan *overlap*. Kontrak keluaran tetap sama walaupun cara pemotongannya berbeda. Relasi struktur dan urutan seperti *previous* dan *next* dipertahankan untuk membantu penelusuran antarpotongan. Representasi yang dievaluasi hanya berupa teks. Isi visual gambar dan tabel tidak dievaluasi sebagai representasi multimodal.

2.3 Indeks dan Materialisasi

Sparse indexer menyiapkan representasi untuk pencocokan istilah. *Dense indexer* membentuk representasi melalui model *embedding*. *Hybrid retrieval* menggabungkan peringkat kandidat dari kedua jalur melalui *Reciprocal Rank Fusion*. Dengan kontrak yang sama, perbandingan dapat memusatkan perubahan pada strategi pencarian tanpa membentuk ulang definisi unit sumber.

CanonicalIndex disimpan di *object storage* sebelum dimaterialisasi ke OpenSearch. Pemisahan hasil transformasi dari materialisasi memungkinkan pengiriman ulang ketika penyimpanan indeks gagal. Sistem menggunakan PostgreSQL untuk data operasional, RabbitMQ untuk pemrosesan asinkron, dan Neo4j untuk materialisasi graf. Penyimpanan graf juga diawali dengan penyimpanan *artifact* agar percobaan ulang tidak selalu membutuhkan konstruksi ulang.

2.4 Pembentukan dan Validasi Graf

Knowledge graph bersifat opsional sesuai *profile*. Pada korpus peraturan, strategi deterministik membentuk simpul peraturan dan pasal dari struktur serta *metadata* eksplisit. Relasi merepresentasikan kepemilikan pasal serta hubungan mengubah, menetapkan, dan mencabut antarperaturan. Pendekatan ini menjaga arah hubungan dan sumber yang mendukungnya.

Canonicalization menyeragamkan identitas, tipe, properti, dan label relasi untuk mengurangi duplikasi. Validasi memeriksa asal dan tujuan sisi, arah relasi, cakupan dokumen, dan *provenance*. Relasi tanpa simpul yang sesuai atau tanpa dukungan sumber ditolak. Penghapusan dokumen atau *profile* juga mencakup materialisasi terkait agar pencarian tidak mengembalikan relasi dari sumber yang telah dihapus.

2.5 Pengelolaan Konteks Percakapan

Context PII mendeteksi informasi pribadi, menggantinya dengan penanda, dan menyimpan pemetaan untuk pemulihan pada keluaran yang berwenang. *Guardrail* memeriksa masukan dan konteks untuk mengendalikan instruksi yang tidak sesuai. *History compactor* mengelola ringkasan dan informasi percakapan agar histori yang dibawa tetap sesuai kapasitas konteks. Ketiganya melengkapi pemanfaatan basis pengetahuan, tetapi hasil *retrieval* di artikel ini tidak membuktikan efektivitas keamanan atau pemadatan histori.

3 Rancangan Eksperimen

3.1 Korpus dan Pertanyaan

Korpus *User Manual* terdiri atas sembilan manual Netgear dengan total 1.400 halaman. Model produk yang dicakup adalah CM2000, LM1200, R6350, R7000, RAX120, RAX50, RAXE500, RBK852, dan XR500. Dari struktur bagian dan *block* teks dipilih 100 *intent* menggunakan *seed* 20260831 dengan mempertimbangkan keterwakilan dokumen dan posisi halaman. Setiap *intent* dirumuskan menjadi satu pertanyaan bahasa Inggris dan satu pertanyaan bahasa Indonesia, menghasilkan 200 pertanyaan.

Setiap pasangan bahasa menggunakan satu *block* sumber yang sama sebagai *context reference*. Pertanyaan dan jawaban acuan disusun dengan bantuan model berdasarkan paket konteks. Karena dokumen sumber berbahasa Inggris, pertanyaan bahasa Indonesia mengukur pencarian lintas bahasa. Kedua bahasa diberi bobot yang sama, tetapi 200 pertanyaan tersebut mewakili 100 kebutuhan informasi berpasangan.

Korpus peraturan dibatasi pada bidang pendidikan di Indonesia. Dari populasi awal 8.745 dokumen, 4.459 memiliki keluaran *parser* yang siap diproses secara vektor. Pemeriksaan pasangan sumber dan *hash* menghasilkan 4.453 dokumen valid sebagai kerangka pemilihan. Dokumen yang terhubung melalui relasi perubahan atau pencabutan dikelompokkan menjadi *primary sampling unit* (PSU).

Strata utama dibentuk berdasarkan jenis relasi dan komposisi status hukum. Bentuk peraturan, tahun, dan panjang dokumen digunakan untuk memeriksa keragaman. Pemilihan PSU dilakukan dengan *probability proportional to size* di dalam strata. Seluruh anggota PSU terpilih dipertahankan agar hubungan antarperaturan tidak terputus. Hasilnya adalah 255 dokumen dari 217 PSU.

Sebanyak 25 PSU menyediakan masing-masing empat pertanyaan, sehingga terdapat 100 pertanyaan hukum.

Model menyusun pertanyaan dan jawaban acuan dari konteks yang disiapkan, kemudian *context reference* ditetapkan pada satu atau beberapa ID ayat kanonis. Sebanyak 30 pertanyaan juga memiliki referensi hubungan perubahan, pencabutan, atau garis keturunan untuk evaluasi relasi. Korpus dan pertanyaan dibekukan sebelum dibandingkan antarstrategi.

3.2 Kondisi Pengujian

Eksperimen bersifat *retrieval-only*. Pembentukan jawaban dan *reranking* dinonaktifkan. Konfigurasi API dan *worker* dipertahankan. Perbandingan menggunakan pendekatan *one factor at a time* (OFAT), yaitu mengganti satu komponen sementara komponen pembanding dibuat tetap.

Pada *User Manual*, perbandingan *chunker* menggunakan *hybrid indexer* dan BAAI/BGE-M3. Strategi *structure-aware* memakai *target text block* dengan *parent context* dan batas 512 karakter. Strategi *recursive* dan *sliding-window* menggunakan 512 karakter dengan *overlap* 51 karakter. Perbandingan *indexer* mempertahankan *structure-aware chunker*, lalu mengganti strategi menjadi *sparse*, *dense*, atau *hybrid*.

Pada peraturan, kondisi acuan menggunakan *legal structure-aware chunker*, BAAI/BGE-M3, dan *dense indexer*. Penggantian model ke Indo-LegalBERT, penggantian *chunker*, dan penggantian *indexer* dilakukan secara terpisah. Pengisian konteks induk saat pengukuran dinonaktifkan. Hal ini perlu dibedakan dari konteks struktural yang telah dibawa ketika *chunk* dibentuk.

3.3 Ukuran Evaluasi

Ukuran utama adalah $recall@K$, yaitu proporsi *context reference* yang ditemukan dalam K hasil teratas. Untuk satu pertanyaan q , definisinya dapat dituliskan sebagai

$$R_q@K = \frac{|G_q \cap C_q(K)|}{|G_q|}, \quad (1)$$

dengan G_q sebagai himpunan referensi acuan dan $C_q(K)$ sebagai referensi yang dicakup hasil teratas. Pencocokan dilakukan melalui identitas sumber, bukan kesamaan teks jawaban. Pada *User Manual* yang memiliki satu referensi per pertanyaan, ukuran ini menunjukkan keberhasilan menemukan referensi tersebut. Pada peraturan, satu pertanyaan dapat membutuhkan beberapa referensi.

Precision dan *nDCG* dilaporkan sebagai diagnostik kepadatan hasil relevan dan urutan pencarian, sedangkan pemilihan konfigurasi mengutamakan *recall*. KG *recall* dibaca terpisah pada 30 pertanyaan relasi. Ukuran tersebut menilai penemuan sumber yang memuat hubungan target dan tidak sama dengan evaluasi menyeluruh ketepatan ekstraksi graf.

Nilai K diperiksa pada rentang 5 hingga 60 dengan selang lima. Pada peraturan, titik operasional dipilih ketika kenaikan *recall* paling besar 0,02 untuk setiap penambahan lima kandidat dan tetap demikian pada seluruh nilai berikutnya. Perbandingan model memakai $K = 45$, sedangkan perbandingan *chunker* dan *indexer* memakai $K = 25$. Pada *User Manual*, titik operasional *dense* berada pada

$K = 40$, sementara perbandingan keseluruhan memakai $K = 45$ yang sama bagi seluruh kondisi.

4 Hasil dan Pembahasan

4.1 Pemeliharaan Struktur Dokumen

Tabel 2 menunjukkan bahwa *structure-aware chunker* menghasilkan *recall* tertinggi dalam kedua perbandingan pada $K = 25$. Pada *User Manual*, selisihnya terhadap *recursive* adalah 0,130 dan terhadap *sliding-window* adalah 0,065. Pada peraturan, selisihnya masing-masing 0,04 dan 0,03.

Hasil tersebut konsisten dengan manfaat mempertahankan hubungan *block* dan konteks induknya pada manual, serta batas pasal dan ayat pada peraturan. Namun, perbandingan ini menguji konfigurasi lengkap setiap *chunker*. Tanpa eksperimen tambahan yang menghilangkan konteks induk secara terpisah, seluruh selisih tidak dapat diatribusikan hanya pada satu mekanisme struktural.

4.2 Pencarian pada *User Manual*

Pada $K = 40$, *dense indexer* mencapai *recall* gabungan 0,830. Nilainya adalah 0,850 untuk pertanyaan bahasa Inggris dan 0,810 untuk bahasa Indonesia. Selisih empat poin persentase menunjukkan bahwa pencarian berbasis representasi semantik tetap menemukan sebagian besar referensi ketika bahasa pertanyaan berbeda dari bahasa dokumen.

Untuk membandingkan kondisi pada jumlah kandidat yang sama, Tabel 3 menggunakan $K = 45$. *Dense* mencapai 0,835, lebih tinggi daripada *hybrid baseline* sebesar 0,745 dan *sparse* sebesar 0,465. *Recursive* dan *sliding-window* pada tabel ini tetap menggunakan *hybrid indexer*.

Pertanyaan mengenai gejala dan prosedur dapat memakai parafrasa yang tidak muncul secara literal dalam manual. Karena itu, hasil *dense* sesuai dengan kebutuhan pencarian berdasarkan makna. Penambahan jalur pencocokan istilah pada *hybrid* belum tentu membantu setiap pertanyaan, terutama pada pencarian lintas bahasa. Gambar 1 memperlihatkan hubungan cakupan pencarian dengan jumlah kandidat.


4.3 Pencarian pada Peraturan

Pada pemilihan model dengan $K = 45$, BAAI/BGE-M3 mencapai *recall* 0,65, sedangkan Indo-LegalBERT mencapai 0,45. Hasil ini mendasari penggunaan BAAI/BGE-M3 sebagai model acuan pada perbandingan komponen

Tabel 2: *Recall* perbandingan *chunker*, $K = 25$.

Strategi	<i>User Manual</i>	Peraturan
<i>Structure-aware</i>	0,740	0,64
<i>Recursive</i>	0,610	0,60
<i>Sliding-window</i>	0,675	0,61

Strategi peraturan menggunakan varian *legal structure-aware*. *Indexer* dibuat tetap dalam setiap korpus, yaitu *hybrid* untuk *User Manual* dan *dense* untuk peraturan.



Gambar 1: Recall pada *User Manual* untuk berbagai nilai K .

Tabel 3: Hasil *User Manual* pada $K = 45$.

Kondisi	Recall	Precision	nDCG
Hybrid baseline	0,745	0,033	0,339
Recursive	0,630	0,022	0,294
Sliding-window	0,685	0,028	0,325
Sparse	0,465	0,023	0,177
Dense	0,835	0,045	0,380

berikutnya. Temuan tersebut terbatas pada konfigurasi dan pertanyaan yang digunakan.

Pada $K = 25$, *hybrid indexer* memperoleh *recall* tertinggi sebesar 0,67, sedangkan *dense* dan *sparse* sama-sama mencapai 0,64 (Tabel 4). Pertanyaan hukum dapat menggabungkan istilah atau identitas peraturan yang eksplisit dengan uraian kebutuhan informasi. Kombinasi pencocokan istilah dan makna memberikan cakupan lebih tinggi pada korpus ini.

Keunggulan *recall* tidak berarti seluruh ukuran ikut tertinggi. *Sparse* menghasilkan *precision* 0,071, sedangkan *dense* menghasilkan *nDCG* 0,445. Pemilihan *hybrid* mengikuti tujuan menemukan referensi sebanyak mungkin sebelum tahap *downstream*. Nilai *precision* yang rendah juga memperlihatkan bahwa kandidat masih mengandung banyak bagian yang tidak relevan. Peningkatan kualitas jawaban setelah *reranking* belum diuji.

4.4 Penelusuran Hubungan dalam Graf

Pada 30 pertanyaan relasi dan $K = 25$, *sparse* menghasilkan *KG recall* 0,517, diikuti *hybrid* 0,417, *sliding-window* 0,350, serta *dense baseline* dan *recursive* masing

Tabel 4: Hasil peraturan pada $K = 25$.

Kondisi	Recall	Precision	nDCG
Dense baseline	0,64	0,047	0,445
Indo-LegalBERT	0,43	0,025	0,203
Recursive	0,60	0,038	0,381
Sliding-window	0,61	0,040	0,407
Sparse	0,64	0,071	0,358
Hybrid	0,67	0,068	0,437

masing 0,300. Penggantian model ke Indo-LegalBERT menghasilkan 0,150. Gambar 2 menampilkan perubahan ukuran ini terhadap K .


Keunggulan *sparse* pada kelompok ini konsisten dengan pertanyaan yang menyebut entitas atau penanda peraturan secara eksplisit. Hasilnya tidak bertentangan dengan keunggulan *hybrid* pada keseluruhan pertanyaan karena cakupan evaluasinya berbeda. Evaluasi ini merupakan diagnostik penelusuran relasi pada korpus peraturan. Tidak tersedia hasil kuantitatif pembanding graf pada *User Manual* dalam eksperimen yang dirangkum.

4.5 Implikasi dan Keterbatasan

Arsitektur *plugin* menyediakan tempat untuk menerapkan strategi yang berbeda tanpa mengubah kontrak informasi. Pada dua korpus ini, pemeliharaan struktur memberi hasil *chunking* terbaik, tetapi strategi pencarian terpilih berbeda. Oleh karena itu, perluasan *domain* perlu disertai evaluasi konfigurasi, bukan sekadar penggunaan ulang konfigurasi lama.

Angka antarkorpus tidak dapat dibaca sebagai perbandingan langsung tingkat kesulitan. Korpus, jumlah referensi acuan, bahasa, dan nilai K berbeda. Pasangan pertanyaan dualbahasa juga berbagi konteks, sementara pertanyaan hukum dari PSU yang sama berbagi sumber. Jumlah pertanyaan karena itu tidak sama dengan jumlah observasi yang sepenuhnya independen.

Pemilihan peraturan hanya mencakup dokumen yang siap diproses secara vektor. Manual terbatas pada sembelan produk Netgear. Pertanyaan disusun dengan bantuan model dari konteks acuan, sehingga belum tentu mencerminkan distribusi pertanyaan pengguna nyata. OFAT belum menguji interaksi antarkomponen, dan tidak ada klaim signifikansi statistik atas selisih hasil. Pengukuran kualitas jawaban, biaya operasional, keamanan, dan efektivitas komponen percakapan memerlukan evaluasi tersendiri.



Gambar 2: KG recall pada pertanyaan relasi peraturan.

5 Kesimpulan

Omni-RAG menyediakan konstruksi basis pengetahuan melalui *chunker*, *indexer*, dan pembangun *knowledge graph* berbasis *plugin*. Kontrak *canonical artifact* mempertahankan identitas serta hubungan ke sumber sehingga strategi dapat diganti dengan batas integrasi yang sama.

Pada $K = 25$, *structure-aware chunker* mencapai *recall* 0,740 pada *User Manual* dan 0,64 pada peraturan. Untuk perbandingan keseluruhan dalam setiap korpus, *dense* mencapai 0,835 pada $K = 45$ untuk *User Manual*, sedangkan *hybrid* mencapai 0,67 pada $K = 25$ untuk peraturan. Pada pertanyaan relasi hukum, *sparse* mencapai *KG recall* tertinggi sebesar 0,517 pada $K = 25$. Hasil ini menunjukkan perlunya menyesuaikan strategi dengan struktur dokumen dan karakteristik pertanyaan.

Pengembangan berikutnya mencakup pengujian kombinasi komponen secara *full factorial*, perluasan korpus dan pertanyaan pengguna, serta evaluasi jawaban akhir. Pengembangan *plugin* juga perlu dilengkapi validasi versi kontrak, dependensi, dan pengujian kompatibilitas untuk mendukung penggunaan pada sumber baru.

Daftar Pustaka

- [1] P. Lewis et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Apr. 12, 2021. arXiv: 2005.11401 [cs]. URL: <http://arxiv.org/abs/2005.11401> (visited on 12/24/2025). Pre-published.
- [2] S. Robertson and H. Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *FNT in Information Retrieval 3.4* (2009), pp. 333–389.
- [3] V. Karpukhin et al. “Dense Passage Retrieval for Open-Domain Question Answering”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, Nov. 2020, pp. 6769–6781. arXiv: 2004.04906.
- [4] N. Thakur et al. “BEIR: A Heterogeneous Benchmark for Zero-Shot Evaluation of Information Retrieval Models”. In: *Proceedings of the 35th Conference on Neural Information Processing Systems Track on Datasets and Benchmarks*. Neural Information Processing Systems Foundation, 2021.