

Pengembangan Sistem Deteksi Inkonsistensi dan Analisis Kepatuhan pada Kontrak Publik Menggunakan Metode Retrieval-Augmented Generation (RAG)

Laporan Tugas Akhir - CAPSTONE Agentic AI untuk Otomasi Analisis Kontrak Publik

Disusun sebagai syarat kelulusan tingkat sarjana

Oleh

Rayendra Althaf Taraka Noor

NIM: 13522107



**PROGRAM STUDI TEKNIK INFORMATIKA
SEKOLAH TEKNIK ELEKTRO & INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG**

Juni 2026

Pengembangan Sistem Deteksi Inkonsistensi dan Analisis Kepatuhan pada Kontrak Publik Menggunakan Metode Retrieval-Augmented Generation (RAG)

Laporan Tugas Akhir - CAPSTONE Agentic AI untuk Otomasi Analisis Kontrak Publik

Oleh

Rayendra Althaf Taraka Noor

NIM: 13522107

Program Studi Teknik Informatika

Sekolah Teknik Elektro dan Informatika


Institut Teknologi Bandung

Bandung, 30 Juni 2026

Mengetahui,

Pembimbing I,

Pembimbing II,



Nugraha Priya Utama, S.T, M.A, Ph.D.
NIP. 118110074

Dr. Eng. Ayu Purwarianti, S.T., M.T.
NIP. 197701272008012011

LEMBAR IDENTITAS

TUGAS AKHIR CAPSTONE

Judul Proyek TA : Agentic AI untuk Otomasi Analisis Kontrak Publik


Anggota Tim dan Pembagian Peran:

No.	NIM	Nama	Peran
1	13522043	Daniel Mulia Putra Manurung	Pembangunan Modul Ekstraksi Teks dengan OCR
2	13522052	Haikal Assyauqi	Pembangunan Agentic AI dengan Reflexion untuk End to End Pipeline dan Evaluasi Kontrak Publik
3	13522107	Rayendra Althaf Taraka Noor	Pembangunan Modul LLM dengan RAG untuk Menganalisis Dokumen Kontrak

Bandung, 30 Juni 2026
Mengetahui,

Pembimbing I,

Pembimbing II,


Nugraha Priya Utama, S.T, M.A, Ph.D.
NIP. 118110074

Dr. Eng. Ayu Purwarianti, S.T, M.T
NIP. 197701272008012011

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa:

1. Pengerjaan dan penulisan Laporan Tugas Akhir ini dilakukan tanpa menggunakan bantuan yang tidak dibenarkan.
2. Segala bentuk kutipan dan acuan terhadap tulisan orang lain yang digunakan di dalam penyusunan laporan tugas akhir ini telah dituliskan dengan baik dan benar.
3. Laporan Tugas Akhir ini belum pernah diajukan pada program pendidikan di perguruan tinggi mana pun.

Jika terbukti melanggar hal-hal di atas, saya bersedia dikenakan sanksi sesuai dengan Pelanggaran Peraturan Akademik dan Kemahasiswaan Institut Teknologi Bandung khususnya Pasal 14.

Bandung, 30 Juni 2026

Rayendra Althaf Taraka Noor
NIM 13522107

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul "Pengembangan Sistem Deteksi Inkonsistensi dan Analisis Kepatuhan pada Kontrak Publik Menggunakan Metode *Retrieval-Augmented Generation* (RAG)".

Laporan ini disusun sebagai salah satu syarat kelulusan tingkat sarjana di Program Studi Teknik Informatika, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung. Penulisan laporan ini merupakan bagian dari pelaksanaan Tugas Akhir yang menjadi puncak dari proses pembelajaran selama menempuh studi.

Penulis menyadari bahwa penyelesaian Tugas Akhir hingga penyusunan laporan ini tidak lepas dari bimbingan, dukungan, dan bantuan berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih yang sebesar-besarnya kepada:

1. Bapak Nugraha Priya Utama, S.T, M.A, Ph.D. dan Ibu Dr. Eng. Ayu Purwarianti, S.T, M.T, selaku dosen pembimbing yang telah meluangkan waktu untuk memberikan arahan, masukan, dan evaluasi yang sangat berharga selama proses pengerjaan Tugas Akhir dan penyusunan laporan ini.
2. Seluruh staf pengajar dan tenaga kependidikan Program Studi Teknik Informatika Institut Teknologi Bandung, atas ilmu, bimbingan, dan dukungan yang diberikan selama penulis menempuh masa studi.
3. Orang tua dan seluruh anggota keluarga, atas doa, dukungan moral, dan semangat yang tidak henti-hentinya diberikan kepada penulis agar dapat menyelesaikan studi dan Tugas Akhir ini dengan baik.
4. Seluruh teman-teman penulis, atas kebersamaan, dukungan, dan diskusi yang membangun selama masa perkuliahan hingga penyelesaian Tugas Akhir ini.

Penulis menyadari bahwa laporan ini masih jauh dari kesempurnaan, baik dari segi penyusunan maupun materi. Oleh karena itu, penulis sangat terbuka terhadap kritik dan saran yang membangun guna penyempurnaan laporan ini di masa mendatang.

Akhir kata, penulis berharap semoga ilmu dan hasil yang tertuang dalam laporan ini dapat memberikan manfaat, baik bagi penulis pribadi, pembaca, maupun bagi pengembangan teknologi di bidang hukum dan pengadaan publik di Indonesia.

Bandung, 30 Juni 2026

Rayendra Althaf Taraka Noor
NIM 13522107

Daftar Isi

LEMBAR PERNYATAAN.....	iii
KATA PENGANTAR.....	iv
Daftar Isi.....	vi
Daftar Gambar.....	ix
Daftar Tabel.....	x
Daftar Istilah.....	xi
BAB I PENDAHULUAN.....	1
I.1. Latar Belakang.....	1
I.2. Rumusan Masalah.....	3
I.3. Tujuan.....	3
I.4. Batasan Masalah.....	4
I.5. Metodologi.....	5
I.6. Sistematika Pembahasan.....	6
BAB II STUDI LITERATUR.....	8
II.1 Large Language Model (LLM).....	8
II.1.1 Arsitektur Transformer.....	8
II.1.1.1 Model Encoder-Only.....	10
II.1.1.2 Model Decoder-Only.....	11
II.1.1.3 Model Encoder-Decoder.....	12
II.1.2 In-Context Learning dan Prompt Engineering.....	13
II.1.2.1 Mekanisme In-Context Learning.....	13
II.1.2.2 Teknik Prompt Engineering.....	14
II.1.2.3 Chain-of-Thought Prompting pada Kasus Hukum.....	15
II.2 Retrieval-Augmented Generation (RAG).....	17
II.2.1 Definisi dan Arsitektur Retrieval-Augmented Generation.....	17
II.2.2 Strategi Text Chunking.....	20
II.3 Model Embedding.....	22
II.3.1 M3-Embedding (BGE-M3).....	23
II.3.2 Jina-Embeddings-v3.....	23
II.3.3. Reranking.....	24
II.4 Metrik Evaluasi Sistem RAG.....	25
II.4.1 Evaluasi Komponen Retrieval.....	25
II.4.2 Evaluasi Komponen Generasi.....	27
II.5 Penelitian Terkait.....	29
II.5.1 LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models.....	29
II.5.2 LegalBench-RAG: A Benchmark for Retrieval-Augmented Generation in the Legal Domain.....	30

II.5.3 Reconstructing Context: Evaluating Advanced Chunking Strategies for Retrieval-Augmented Generation.....	31
BAB III ANALISIS MASALAH DAN RANCANGAN SOLUSI.....	35
III.1 Deskripsi Aplikasi.....	35
III.2 Analisis Masalah.....	35
III.3 Gambaran Umum Solusi.....	37
III.3.1 Penggunaan Kakas pada Sistem.....	41
III.3.2 Data.....	42
III.3.3 Implementasi Pipeline Chunking.....	44
III.3.4 Implementasi Tahap Retrieval.....	46
III.3.5 Implementasi Pipeline Analisis Kepatuhan.....	46
III.3.6 Implementasi Pipeline Analisis Entitas.....	48
III.3.7 Keterbatasan Penanganan Perubahan Regulasi.....	49
III.3.8 Pengujian Sistem.....	52
III.3.9 Evaluasi Hasil.....	53
III.4 Rancangan Eksperimen.....	53
III.4.1 Eksperimen Strategi Chunking.....	53
III.4.2 Eksperimen Strategi Retrieval.....	53
III.4.3 Eksperimen Ukuran LLM.....	54
III.4.4 Eksperimen Reranking.....	54
III.4.5 Eksperimen Strategi Instruksi (Prompt).....	54
BAB IV EKSPERIMEN DAN EVALUASI.....	55
IV.1 Lingkungan Eksperimen.....	55
IV.2 Dataset.....	56
IV.2.1 Dataset Regulasi.....	56
IV.2.2 Dataset Kontrak Publik.....	57
IV.3 Eksperimen Strategi Chunking.....	57
IV.3.1 Konfigurasi Eksperimen.....	58
IV.3.2 Hasil Evaluasi.....	58
IV.3.3 Analisis.....	59
IV.4 Eksperimen Strategi Retrieval.....	60
IV.4.1 Konfigurasi Eksperimen.....	60
IV.4.2 Hasil Evaluasi.....	61
IV.4.3 Analisis.....	61
IV.5 Eksperimen Reranking.....	62
IV.5.1 Konfigurasi Eksperimen.....	62
IV.5.2 Hasil Evaluasi.....	63
IV.5.3 Analisis.....	63
IV.6 Eksperimen Model.....	64
IV.6.1 Konfigurasi Eksperimen.....	64
IV.6.2 Hasil Evaluasi.....	65

IV.6.3 Analisis.....	66
IV.7 Eksperimen Instruksi (Prompt).....	67
IV.7.1 Konfigurasi Eksperimen.....	67
IV.7.2 Hasil Evaluasi.....	68
IV.7.3 Analisis.....	68
BAB V KESIMPULAN DAN SARAN.....	70
V.1 Kesimpulan.....	70
V.2 Saran.....	71
REFERENSI.....	73

Daftar Gambar

Gambar II.1 Diagram Arsitektur Dasar Transformer.....	10
Gambar II.2 Perbandingan Arsitektur BERT dengan beberapa model pre-trained lain.....	11
Gambar II.3 Tiga Pendekatan untuk Legal judgment prediction.....	16
Gambar II.4 Overview Pendekatan Awal RAG.....	18
Gambar II.5 Perbandingan Mekanisme Early Chunking vs Late Chunking.....	21
Gambar II.6 Perbandingan Early vs Late Retriever pada NFCorpus.....	32
Gambar II.7 Perbandingan Early vs Late Retriever pada MSMacro.....	33
Gambar II.8 Perbandingan Late Chunking vs Contextual Retrieval pada NFCorpus.....	33
Gambar III.1 Pipeline Analisis Kepatuhan.....	37
Gambar III.2 Pipeline Analisis Entitas.....	38
Gambar III.3. Skema Basis Data Regulasi.....	43
Gambar III.4. Skema Basis Data Kontrak Publik.....	44
Gambar III.5. Potongan Penulisan Perubahan Peraturan.....	51
Gambar III.6. Potongan Penulisan Peraturan dengan Struktur Unik.....	52

Daftar Tabel

Tabel III.1 Tabel Masalah.....	30
Tabel III.2 Gambaran Umum Solusi.....	33
Tabel III.3 Kakas.....	34
Tabel III.4 Proses Chunking.....	38
Tabel III.5 Proses Analisis Kepatuhan.....	39
Tabel III.6 Proses Analisis Entitas.....	40
Tabel IV.1. Spesifikasi Lingkungan Eksperimen.....	45
Tabel IV.2. Skenario Eksperimen.....	46
Tabel IV.3. Konfigurasi Strategi Chunking.....	48
Tabel IV.4 Hasil Evaluasi Strategi Chunking (Mean Context Relevance).....	49
Tabel IV.5 Konfigurasi Strategi Retrieval.....	50
Tabel IV.6 Hasil Evaluasi Strategi Retrieval (Mean Context Relevance).....	51
Tabel IV.7 Konfigurasi Eksperimen Reranking.....	52
Tabel IV.8 Hasil Evaluasi Reranking (Mean Context Relevance dan Latensi Retrieval).....	53
Tabel IV.9 Spesifikasi Model yang Dibandingkan.....	55
Tabel IV.10 Hasil Evaluasi Perbandingan Model untuk Pipeline Analisis Kepatuhan.....	55
Tabel IV.11 Hasil Evaluasi Perbandingan Model untuk Pipeline Analisis Entitas.....	55
Tabel IV.12 Deskripsi Strategi Prompt.....	57
Tabel IV.13 Hasil Evaluasi Strategi Prompting.....	58

Daftar Istilah

<i>Retrieval-Augmented Generation</i> (RAG)	Paradigma arsitektur yang menggabungkan model bahasa generatif (memori parametrik) dengan sistem pencarian dokumen eksternal (memori non-parametrik) untuk menyediakan konteks terkini dan mengurangi halusinasi (Lewis et al., 2020).
<i>Transformer</i>	Arsitektur jaringan saraf berbasis mekanisme <i>Self-Attention</i> yang memungkinkan pemrosesan teks secara paralel dan mampu menangkap hubungan ketergantungan antar kata dalam jarak jauh (<i>long-range dependencies</i>) (Vaswani et al., 2017).
<i>In-Context Learning</i>	Kemampuan model bahasa untuk mempelajari dan menyelesaikan tugas baru hanya dengan diberikan instruksi atau contoh demonstrasi dalam <i>prompt</i> pada saat inferensi, tanpa memperbarui bobot model (Brown et al., 2020).
Inkonsistensi Data	Kondisi munculnya perbedaan, konflik, atau ketidaksesuaian informasi pada entitas data yang sama (seperti identitas, nilai, atau tanggal) yang tersimpan dalam dokumen atau lokasi yang berbeda (Sanjaya dan Sulistyio, 2015).
<i>Halusinasi</i> (dalam AI)	Fenomena di mana model generatif memproduksi informasi atau fakta yang tampak meyakinkan namun salah, fiktif, atau tidak didukung oleh sumber referensi yang diberikan (Ji et al., 2023).

BAB I PENDAHULUAN

Bab ini menjabarkan tentang latar belakang, rumusan masalah, tujuan, batasan masalah, dan metodologi dari penelitian tentang pemanfaatan *Retrieval Augmented Generation* (RAG) dan *Large Language Model* (LLM) dalam sistem analisis kontrak publik. Secara berurutan, bagian-bagian tersebut disusun untuk menguraikan motivasi dasar diangkatnya topik ini, tantangan utama yang hendak diselesaikan, target capaian, ruang lingkup agar pembahasan tetap terarah, serta tahapan sistematis dalam pelaksanaannya.

I.1. Latar Belakang

Pengadaan barang dan jasa melalui kontrak publik merupakan instrumen fundamental di Indonesia karena diperlukan untuk memastikan pengadaan barang/jasa memberikan pemenuhan nilai manfaat yang sebesar-besarnya (Perpres No.16, 2018). Setiap tahunnya, pemerintah mengalokasikan porsi anggaran yang signifikan untuk berbagai proyek yang direalisasikan melalui mekanisme kontrak ini, mulai dari pembangunan infrastruktur hingga penyediaan layanan esensial bagi masyarakat. Mengingat vitalnya peran kontrak publik, proses analisis dan monitoring untuk memastikan kepatuhan terhadap kerangka regulasi yang berlaku menjadi sebuah aktivitas krusial. Proses ini bertujuan untuk menjaga akuntabilitas, mencegah penyimpangan, dan menjamin bahwa dana publik dimanfaatkan secara efektif dan efisien.

Meskipun demikian, praktik yang berjalan saat ini untuk analisis kontrak publik masih sangat bergantung pada proses manual. Verifikasi setiap klausul, perbandingan dengan pasal-pasal dalam peraturan terkait, serta identifikasi potensi anomali dilakukan secara manual oleh tenaga ahli seperti staf legal. Pendekatan konvensional ini memiliki kelemahan yakni tidak aksesibel (perlu tenaga ahli), memakan waktu yang lama, dan ongkos yang mahal (Hendrycks et al., 2021).

Permasalahan mendasar dalam dokumen hukum sering kali berakar pada fenomena inkonsistensi data. Inkonsistensi data muncul ketika ada perbedaan atau konflik yang terjadi pada data yang sama yang disimpan di tempat yang berbeda (Sanjaya dan Sulisty, 2015). Dalam konteks kontrak publik, hal ini mencakup ketidaksesuaian penulisan identitas, tanggal, nilai kontrak, hingga perbedaan nilai-nilai yang melekat pada barang atau jasa. Konsistensi di sini sangat penting untuk menjaga prinsip kepastian hukum. Gustav Radbruch, dalam teori tujuan

hukumnya, menegaskan bahwa kepastian hukum (*Sicherheit des Rechts selbst*) menuntut agar hukum bersifat positif, jernih, tetap, dan konsisten sehingga subjek hukum dapat menyesuaikan perilaku mereka tanpa keraguan (Radbruch, 1950). Inkonsistensi data akan merusak struktur kepastian ini, membuka celah untuk terjadinya penyalahgunaan dan tindakan koruptif.

Efektivitas kontrak publik tentu tergantung pada kepatuhan hukum. Kepatuhan hukum dapat didefinisikan sebagai kondisi dimana perilaku subjek hukum selaras dengan nilai-nilai yang terkandung dalam norma hukum yang berlaku (Rahardjo, 2009). Urgensi dari kepatuhan hukum di Indonesia adalah untuk mewujudkan ketertiban dan kepastian hukum.

Praktik pengawasan kepatuhan pengadaan barang/jasa di Indonesia saat ini secara formal dijalankan oleh Aparat Pengawasan Intern Pemerintah (APIP) melalui mekanisme audit pengadaan yang pedomannya ditetapkan dalam Peraturan Badan Pengawasan Keuangan dan Pembangunan (BPKP) Nomor 3 Tahun 2019 Pengadaan Barang/Jasa Pemerintah (BPKP, 2019). Secara metodologis, audit ini mengandalkan empat teknik utama yang seluruhnya bersifat manual, yaitu audit, reviu, evaluasi, dan pemantauan. Pendekatan berbasis pemeriksaan manual ini menghadapi sejumlah keterbatasan mendasar. Pertama, proses bergantung pada ketersediaan auditor. Kedua, telaah dokumen yang panjang menuntut waktu yang lama serta rentan terhadap kelelahan dan inkonsistensi antara pemeriksa. Ketiga regulasi pengadaan kerap berubah, auditor harus terus memutakhirkan rujukan secara manual. Keterbatasan-keterbatasan ini membuka ruang bagi pendekatan terotomasi sebagai pelengkap proses pemeriksaan konvensional.

Guna mengatasi tantangan tersebut, pemanfaatan berbagai macam metode otomasi akan menjadi solusi yang relatif murah dan tidak rentan terhadap *human error*. Sebelum era *deep learning*, tugas-tugas *natural language processing* sangat bergantung pada pendekatan statistik dan pendekatan berbasis aturan yang memerlukan rekayasa fitur manual dan memiliki keterbatasan dalam memahami semantik (Jurafsky & Martin, 2025). Kemudian diperkenalkan beberapa model *deep learning* seperti *Recurrent Neural Network* (RNN) dan *Long Short-Term Memory* (LSTM). Keterbatasan pada model ini adalah kesulitan dalam menangkap hubungan antar-kata yang berjauhan. Keterbatasan yang fatal dalam menganalisis dokumen hukum. Titik balik terjadi dengan diperkenalkannya *Transformer*, sebuah arsitektur *deep learning* yang memproses teks secara paralel dan dapat menghubungkan setiap kata dalam teks tanpa pengaruh jarak. Oleh sebab itu, dipilih penggunaan sistem penalaran berbasis *Large-Language Model* (LLM). Basis

sistem yang dinilai memiliki kemampuan penalaran yang cukup baik untuk permasalahan hukum (Katz et al., 2024).

Untuk mengotomatisasi analisis kepatuhan hukum, mekanisme *Retrieval-Augmented Generation* (RAG) dipilih sebagai arsitektur yang dinilai lebih cocok dibandingkan penggunaan mekanisme *fine-tuning* pada model dasar. RAG dinilai lebih unggul karena kemampuannya dalam menggunakan pengetahuan eksternal (di luar pengetahuan parametrik) sehingga peraturan yang digunakan bisa terus diperbarui tanpa perlu dilakukannya pelatihan ulang (Lewis et al., 2020). Hal ini sangat krusial untuk domain hukum yang bersifat dinamis, dimana peraturan-peraturan di dalamnya akan terus diperbarui seiring dengan berjalannya waktu. Melalui RAG, sistem dapat melakukan pengambilan pasal-pasal yang relevan sebagai konteks sebelum menghasilkan analisis, sehingga memitigasi risiko halusinasi AI dan memberikan unsur penjelasan atas hasil yang diberikan.

I.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, muncul peluang untuk mengatasi tantangan digitalisasi analisis kontrak dengan mengintegrasikan teknologi kecerdasan artifisial pada proses yang sebelumnya dilakukan secara manual. Mengingat luasnya permasalahan yang bisa muncul pada ranah hukum, penelitian kali ini akan dikerucutkan pada dua masalah:

1. Bagaimana merancang dan membangun sistem berbasis *Large-Language Model* (LLM) untuk mendeteksi inkonsistensi data secara otomatis di dalam dokumen kontrak publik?
2. Bagaimana mengembangkan sistem yang mampu menganalisis kepatuhan dokumen kontrak terhadap basis data peraturan yang relevan secara akurat dengan memanfaatkan mekanisme *Retrieval-Augmented Generation* (RAG)?

I.3. Tujuan

Berdasarkan rumusan masalah yang telah dipaparkan, tujuan utama dari penelitian ini adalah untuk mengembangkan sebuah prototipe fungsional berupa sistem yang mampu menguji secara otomatis kepatuhan pada kontrak publik secara akurat dan efisien.

Untuk memastikan pencapaian tujuan utama tersebut, penelitian ini akan berfokus pada pencapaian beberapa tujuan spesifik yang terukur sebagai berikut:

1. Membangun sistem deteksi inkonsistensi entitas dari dokumen kontrak publik yang mampu mengidentifikasi ketidaksesuaian antar entitas terkait, mencakup inkonsistensi nilai moneter, identitas, temporal, serta jenis inkonsistensi lainnya.
2. Membangun sistem analisis kepatuhan berbasis *retrieval augmented generation* (RAG) yang mampu mengidentifikasi ketidaksesuaian klausul kontrak terhadap regulasi pengadaan barang/jasa pemerintah, dengan menghasilkan temuan yang terstruktur yang menyertakan sitasi ke pasal regulasi sebagai dasar penilaian.

I.4. Batasan Masalah

Untuk memastikan penelitian ini berjalan secara fokus dan terarah, serta agar hasil yang dicapai dapat terukur dengan jelas, maka ditetapkan batasan-batasan masalah sebagai berikut. Ruang lingkup penelitian ini secara spesifik mendefinisikan aspek-aspek yang akan dikaji dan dikembangkan, serta hal-hal yang tidak akan menjadi fokus dalam pengerjaan Tugas Akhir ini.

Adapun cakupan penelitian ini adalah sebagai berikut:

1. Sumber Peraturan: Pengecekan kepatuhan dokumen kontrak hanya akan berdasarkan pada dokumen peraturan di JDIH LKPP, yang berisikan kumpulan peraturan terkait pengadaan barang dan jasa.
2. Batasan Pengambilan Peraturan: Peraturan pada modul hasil akan menggunakan beberapa peraturan JDIH LKPP yang terkait yakni:
 - Peraturan Presiden (Perpres) Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
 - Peraturan Presiden (Perpres) Nomor 46 Tahun 2025 tentang Perubahan Kedua atas Peraturan Presiden Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
 - Peraturan Presiden (Perpres) Nomor 12 Tahun 2021 tentang Perubahan atas Peraturan Presiden Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
 - Peraturan Lembaga Kebijakan Pengadaan Barang/Jasa Pemerintah Nomor 4 Tahun 2024 tentang Perubahan Atas Peraturan Lembaga Kebijakan Pengadaan

Barang/Jasa Pemerintah Nomor 12 Tahun 2021 tentang Pedoman Pelaksanaan
Pengadaan Barang/Jasa Pemerintah Melalui Penyedia

Selain pada batasan di atas, penelitian ini juga akan terbatas sesuai batasan-batasan yang ada pada keseluruhan *capstone*.

I.5. Metodologi

Pelaksanaan tugas akhir akan dilaksanakan dengan tahapan sebagai berikut.

1. Studi Literatur dan Pemahaman Konteks

Pada tahap awal ini, dilakukan studi literatur mendalam untuk memahami lanskap teknologi *state-of-the-art* yang bisa digunakan dalam analisis dokumen hukum, khususnya pada bidang LLM, ekstraksi informasi, dan *Retrieval-Augmented Generation* (RAG). Selain itu, tahap ini juga mencakup analisis terhadap proses bisnis analisis kontrak publik untuk mendefinisikan secara tajam parameter masalah dan kriteria keberhasilan yang akan digunakan untuk evaluasi model.

2. Akuisisi dan Persiapan Data

Tahap ini berfokus pada pengumpulan dan persiapan data yang digunakan untuk mengevaluasi model. Data masukan utama adalah teks terstruktur hasil ekstraksi dari dokumen kontrak PDF yang diproses oleh komponen *Optical Character Recognition* (OCR) (ditangani oleh NIM 13522043). Proses persiapan data mencakup persiapan basis pengetahuan yang berisi peraturan perundang-undangan relevan yang telah disesuaikan untuk mendukung mekanisme RAG yang diisi dengan teks dokumen yang telah dipotong menjadi *chunk* dan dihitung nilai *embedding*-nya.

3. Perancangan dan Implementasi Model Analisis

Tahap inti dari penelitian, di mana arsitektur model untuk deteksi inkonsistensi dan analisis kepatuhan dirancang dan diimplementasikan. Sistem dirancang untuk mengambil informasi kontekstual yang relevan dari basis pengetahuan regulasi dan menyajikannya ke dalam *context window* LLM. Penelitian ini tidak melakukan *fine-tuning* pada model, fokus pengembangan ditekankan pada strategi *retrieval* yang akurat dan perancangan *prompt* yang efektif agar *pre-trained* model dapat melakukan penalaran hukum berdasarkan konteks regulasi yang diberikan.

4. Eksperimen dan Evaluasi Kinerja Model

Pada tahap ini, model yang telah diimplementasikan diuji secara sistematis untuk mengukur kinerjanya. Evaluasi akan dilakukan dengan menggunakan beberapa metrik. Kinerja model diukur berdasarkan metrik-metrik kuantitatif yang telah ditetapkan pada tujuan penelitian, terutama dalam mengidentifikasi ketidaksesuaian klausul dan anomali data.

5. Integrasi, Analisis Hasil, dan Validasi Pengguna

Model yang telah dievaluasi dan divalidasi kinerjanya diintegrasikan sebagai sebuah layanan *backend* ke dalam prototipe aplikasi *full-stack*. Keluaran dari model, seperti daftar anomali dan skor kepatuhan, dianalisis secara kualitatif untuk memastikan hasilnya logis, dapat dijelaskan, dan bermanfaat. Tahap ini diakhiri dengan sesi *User Acceptance Testing* (UAT) untuk memvalidasi bahwa output sistem memenuhi kriteria "jelas dan bermanfaat" bagi calon pengguna.

I.6. Sistematika Pembahasan

Laporan tugas akhir ini disusun ke dalam lima bab yang saling berkaitan sebagai berikut.

1. Bab 1: Latar Belakang

Bab ini berisi bahasan latar belakang yang mendasari penelitian, rumusan masalah, tujuan, batasan masalah, metodologi, serta sistematika pembahasan yang menjadi kerangka penyusunan laporan.

2. Bab 2: Studi Literatur

Bab ini berisi penguraian landasan teoretis dan kajian *state-of-the-art* yang melandasi pengembangan sistem, meliputi *Large Language Model* dan arsitektur *transformer*, *in-context learning* dan *prompt engineering*, paradigma *Retrieval-Augmented Generation* (RAG) beserta strategi *chunking*, model *embedding*, metrik evaluasi sistem RAG, serta berbagai penelitian terkait.

3. Bab 3: Analisis Masalah dan Rancangan Solusi

Bab ini berisi penjabaran deskripsi, analisis permasalahan yang dihadapi, gambaran umum solusi yang diusulkan, rancangan data dan implementasi setiap *pipeline*, mekanisme pengujian, serta rancangan eksperimen yang dilakukan.

4. Bab 4: Eksperimen dan Evaluasi

Bab ini berisi pemaparan lingkungan dan dataset pengujian, diikuti dengan penjelasan mengenai konfigurasi, hasil, dan analisis dari setiap skenario eksperimen yang mencakup strategi *chunking*, strategi *retrieval*, *reranking*, perbandingan model, dan strategi instruksi (*prompt*).

5. Bab 5: Kesimpulan dan Saran

Bab ini berisi rangkuman dari temuan penelitian yang dikaitkan langsung dengan rumusan masalah, serta menyampaikan saran untuk pengembangan lebih lanjut.

BAB II STUDI LITERATUR

Bab ini berisi penguraian landasan teoretis dan penelitian terkini (*state-of-the-art*) terkait teknologi yang bisa dijadikan dasar pengembangan model deteksi anomali dan analisis kepatuhan kontrak. Pembahasan dimulai dari evolusi fundamental dalam bidang *Natural Language Processing* (NLP) berbentuk LLM yang dimotori oleh arsitektur Transformer. Selanjutnya, pembahasan akan mengerucut pada sistem yang bisa digunakan untuk meningkatkan performa sistem LLM yakni *Retrieval-Augmented Generation* (RAG) dan teknik *prompting*. Terakhir, dibahas metrik yang digunakan untuk mengukur keberhasilan sistem dan posisi penelitian ini di antara karya-karya terkait yang sudah ada.

II.1 Large Language Model (LLM)

Bagian ini berisi penjelasan tentang arsitektur *Transformer* yang berpusat pada mekanisme *Self-Attention* dan menjelaskan variasi-variasi turunan dari arsitektur transformer beserta masing-masing keunggulannya.

II.1.1 Arsitektur Transformer

Perkembangan fundamental dalam pemrosesan bahasa alami (NLP) terjadi saat diperkenalkannya arsitektur Transformer oleh Vaswani et al. (2017) dalam makalah berjudul "*Attention Is All You Need*". Sebelum kemunculan Transformer, pemrosesan data sekuensial didominasi oleh *Recurrent Neural Networks* (RNN) dan variannya seperti LSTM (*Long Short-Term Memory*). Meskipun efektif, RNN memiliki kelemahan yang tidak bisa dilepaskan, pemrosesan dilakukan secara berurutan, kata demi kata, yang menghambat paralelisasi komputasi dan menyulitkan model untuk menangkap hubungan *long-range dependencies* dalam teks yang panjang.

Sebelum teks dapat diproses oleh Transformer, masukan terlebih dahulu melalui tahap tokenization, yaitu pemecahan teks menjadi unit-unit diskret yang disebut token. Token dapat berupa kata utuh, potongan kata (*subword*), maupun karakter, bergantung pada algoritma yang digunakan (Jurafsky & Martin, 2025). Setiap token kemudian dipetakan ke sebuah indeks berdasarkan kosakata model, lalu indeks tersebut dikonversi menjadi vektor berdimensi tetap


melalui lapisan *embedding*. Rangkaian vektor inilah, setelah ditambahkan *positional encoding*, yang menjadi masukan sesungguhnya bagi lapisan-lapisan *Transformer*.

Arsitektur Transformer mengatasi keterbatasan tersebut dengan meninggalkan mekanisme rekurensi dan menggantinya dengan mekanisme *Self-Attention*. Mekanisme ini memungkinkan model untuk memproses seluruh urutan input secara paralel dan mengaitkan setiap kata dengan kata lainnya dalam kalimat, terlepas dari seberapa jauh jarak posisinya.

Inti dari inovasi ini adalah unit *Scaled Dot-Product Attention*. Dalam proses ini, setiap token (kata atau bagian kata) dalam input diproyeksikan menjadi tiga vektor representasi:

- *Query* (Q): Representasi token saat ini yang sedang mencari informasi relevan.
- *Key* (K): Representasi token yang berfungsi untuk dicocokkan dengan *Query*.
- *Value* (V): Representasi konten atau informasi aktual dari token tersebut.

Mekanisme atensi menghitung bobot relevansi antara *Query* dari satu token dengan *Key* dari token lainnya. Bobot ini kemudian digunakan untuk mengagregasi *Value*, sehingga model dapat memfokuskan perhatian (*attend*) pada bagian kalimat yang paling relevan secara kontekstual untuk memproses token tersebut.




Gambar II.1 Diagram Arsitektur Dasar Transformer

(Sumber: Vaswani et al., 2017)

Karena *Transformer* memproses seluruh input sekaligus tanpa urutan waktu, arsitektur ini memerlukan Positional Encoding untuk memberikan informasi mengenai urutan relatif atau absolut dari token di dalam kalimat. Hal ini memastikan bahwa model tetap memahami struktur sintaksis bahasa meskipun pemrosesannya dilakukan secara paralel (Vaswani et al., 2017).

II.1.1.1 Model Encoder-Only

Model *Encoder-Only* dirancang untuk memahami struktur bahasa dengan memanfaatkan mekanisme *self-attention* yang bersifat *bidirectional* (dua arah). Dalam arsitektur ini, setiap token dalam kalimat dapat "melihat" seluruh token lain secara bersamaan pada setiap lapisan pemrosesan. Model yang cukup terkenal dari kategori ini adalah BERT (*Bidirectional Encoder Representations from Transformers*) yang diperkenalkan oleh Devlin et al. (2019). Model ini dilatih menggunakan objektif *Masked Language Modeling* (MLM), di mana model dipaksa untuk merekonstruksi token yang sengaja disembunyikan (*masked*) berdasarkan konteks kalimat di sekelilingnya.



Gambar II.2 Perbandingan Arsitektur BERT dengan beberapa model *pre-trained* lain

(Sumber: Devlin et al., 2019)

Karena sifatnya yang melihat konteks secara menyeluruh, model ini sangat unggul dalam tugas-tugas yang bersifat diskriminatif atau pemahaman (*Natural Language Understanding*). Model ini berusaha membangun representasi vektor kaya akan makna semantik untuk setiap token atau kalimat. Kelebihan utamanya adalah kemampuannya menangkap nuansa makna yang bergantung pada konteks ganda, contohnya membedakan makna kata "bisa" sebagai racun atau kemampuan.

Secara empiris, arsitektur Encoder-Only memiliki performa yang cukup baik pada tugas-tugas seperti:

- **Klasifikasi Teks dan Analisis Sentimen:** Menentukan kategori atau emosi dari sebuah dokumen.
- ***Named Entity Recognition*:** Mengidentifikasi entitas seperti nama orang, lokasi, atau organisasi dalam teks hukum.
- ***Extractive Question Answering*:** Menemukan rentang jawaban yang tepat dari sebuah paragraf konteks (*SQuAD Benchmark*).
- ***Semantic Search*:** Mengubah teks menjadi vektor numerik untuk pencarian informasi.

II.1.1.2 Model Decoder-Only

Model *Decoder-Only* menggunakan *decoder* dengan mekanisme *Masked Self-Attention* yang bersifat *unidirectional*. Model ini memproses teks secara sekuensial dari kiri ke kanan dan dilatih

dengan objektif *Causal Language Modeling* (CLM), yaitu memprediksi token berikutnya berdasarkan urutan token sebelumnya. Seri GPT (*Generative Pre-trained Transformer*) oleh Radford et al. (2019) adalah contoh paling prominen dari arsitektur ini.

Kekuatan utama arsitektur ini terletak pada kemampuan generatif (*Natural Language Generation*). Dengan skala parameter yang masif, model ini menunjukkan kemampuan berupa penalaran logis dan *few-shot learning* (belajar dari sedikit contoh dalam *prompt*). Kelebihannya adalah fleksibilitas yang luar biasa, satu model dapat melakukan berbagai tugas berbeda hanya dengan instruksi bahasa alami tanpa perlu adanya perubahan struktur model.

Model Decoder-Only memiliki performa yang baik untuk tugas-tugas yang memerlukan kreativitas atau penalaran kompleks, seperti:

- *Text Generation*: Menulis esai atau draf surat.
- *Complex Reasoning*: Menyelesaikan soal logika atau matematika bertingkat lewat *Chain-of-Thought*.
- *Instruction Following*: Mengikuti perintah spesifik pengguna untuk memformat output.

II.1.1.3 Model Encoder-Decoder

Arsitektur ini mempertahankan desain orisinal *Transformer* yang menghubungkan *encoder* (untuk memahami input) dan *Decoder* (untuk menghasilkan output). *Encoder* memproses seluruh urutan input menjadi representasi konteks, yang kemudian disalurkan ke *decoder* melalui mekanisme cross-attention. Model seperti BART (Lewis et al., 2020) dan T5 (*Text-to-Text Transfer Transformer*) (Raffel et al., 2020) mengadopsi pendekatan ini dengan melatih model untuk mengubah satu bentuk sekuens teks menjadi sekuens lainnya (*Sequence-to-Sequence*).

Arsitektur ini menawarkan keseimbangan antara pemahaman konteks (seperti BERT) dan kemampuan generasi (Raffel et al., 2020). Kelebihannya adalah kemampuannya menangani input dan output dengan panjang yang bervariasi namun tetap mempertahankan koherensi hubungan antara keduanya.

Model *Encoder-Decoder* menunjukkan performa unggul pada tugas transformasi teks, antara lain:

- *Machine Translation*: Menerjemahkan dokumen dari satu bahasa ke bahasa lain.
- *Abstractive Summarization*: Meringkas dokumen panjang menjadi paragraf pendek dengan kalimat baru.
- *Text Paraphrasing*: Menulis ulang kalimat dengan gaya bahasa berbeda tanpa mengubah makna.

II.1.2 In-Context Learning dan Prompt Engineering

Perkembangan terkini dalam teknologi *Large-Language Model* (LLM) telah mencapai pergeseran fundamental dalam pemrosesan bahasa alami. Pendekatan konvensional yang sebelumnya hanya bergantung pada metode *pre-train* lalu *fine-tune* kini mulai beralih menuju paradigma baru yang dikenal sebagai *pre-train, prompt, and predict* (Liu et al., 2023). Dalam kerangka kerja baru ini, model tidak lagi memerlukan modifikasi pada parameter internal atau bobotnya untuk beradaptasi dengan tugas baru. Kini, model dapat memanfaatkan kemampuan generalisasi yang telah diperoleh selama pelatihan awal untuk menyelesaikan tugas hilir hanya dengan pengkondisian instruksi tekstual. Pendekatan ini menjadi landasan metodologis penelitian ini, yang memungkinkan pengembangan sistem analisis kontrak tanpa memerlukan proses pelatihan ulang yang memakan sumber daya besar.

II.1.2.1 Mekanisme In-Context Learning

In-Context Learning (ICL) didefinisikan sebagai kemampuan model bahasa untuk mempelajari pola tugas baru pada saat inferensi tanpa adanya pembaruan nilai gradien. Konsep ini dipaparkan oleh Brown et al. (2020) melalui model GPT-3, yang menunjukkan bahwa model berskala besar mampu memprediksi label yang benar hanya dengan mengamati konteks yang diberikan dalam prompt. Penelitian lebih lanjut oleh Olsson et al. (2022) mengaitkan fenomena ini dengan mekanisme *induction heads* dalam lapisan atensi Transformer, yang memungkinkan model untuk menyalin pola algoritma dari konteks sebelumnya dan menerapkannya pada input baru.

Secara umum, pendekatan ICL dapat diklasifikasikan ke dalam tiga tingkatan berdasarkan jumlah informasi atau demonstrasi yang diberikan kepada model:

- *Zero-Shot Learning*: Pada tingkatan ini, model hanya diberikan deskripsi tugas atau instruksi dalam bahasa alami tanpa disertai contoh pasangan input-output. Model sepenuhnya mengandalkan pengetahuan parametrik yang tersimpan dalam bobotnya untuk memahami dan mengeksekusi instruksi tersebut.
- *One-Shot Learning*: Model diberikan satu contoh demonstrasi yang relevan sebelum diminta untuk menyelesaikan input baru. Contoh tunggal ini berfungsi untuk memberikan sinyal mengenai format output yang diharapkan.
- *Few-Shot Learning*: Model diberikan sekumpulan contoh demonstrasi di dalam prompt. Metode ini terbukti paling efektif karena kumpulan contoh tersebut berfungsi sebagai "jangkar" yang mengarahkan model untuk mengenali pola logika dan struktur penyelesaian masalah yang spesifik.

Dalam konteks analisis kontrak, pendekatan *few-shot learning* menawarkan keuntungan signifikan karena memungkinkan sistem untuk mengajarkan model mengenai format laporan audit yang kompleks tanpa perlu menyusun ribuan data latih berlabel.

II.1.2.2 Teknik Prompt Engineering


Agar kemampuan *In-Context Learning* dapat dimanfaatkan secara optimal, diperlukan perancangan instruksi yang presisi, sebuah disiplin teknis yang dikenal sebagai *Prompt Engineering*. White et al. (2023) dalam penelitiannya mengenai katalog pola *prompt* mendefinisikan disiplin ini sebagai metode sistematis untuk menginstruksikan LLM guna menyelesaikan masalah, yang melampaui sekadar penyusunan pertanyaan sederhana. Dalam konteks pengembangan sistem otomatisasi legal, *prompt* berfungsi sebagai antarmuka utama yang mengontrol perilaku model, memitigasi ambiguitas, dan memastikan format output yang terstruktur. Berdasarkan survei literatur terkini, terdapat beberapa prinsip dan teknik utama yang terbukti efektif untuk meningkatkan kinerja model pada tugas domain spesifik:

- *Persona Pattern*: Teknik ini melibatkan pemberian peran spesifik kepada model di awal instruksi, misalnya sebagai "Auditor Hukum Senior" atau "Ahli Kontrak Pemerintah". Reynolds dan McDonell (2021) menjelaskan bahwa teknik ini bekerja dengan cara mengarahkan model ke *latent space* yang relevan dengan peran tersebut. Dengan menetapkan persona, model secara implisit mengadopsi terminologi, nada bicara, dan kerangka berpikir yang diasosiasikan dengan profesi hukum, sehingga menghasilkan output yang lebih akurat secara kontekstual dibandingkan instruksi generik.
- *Instruction Tuning*: Ouyang et al. (2022) melalui penelitian InstructGPT menunjukkan bahwa kemampuan model untuk mengikuti niat pengguna sangat bergantung pada kejelasan instruksi. Dalam analisis legal, hal ini diterjemahkan menjadi pemberian batasan yang ketat, seperti perintah negatif ("jangan menambahkan asumsi di luar teks") dan spesifikasi format output (misalnya, "hasilkan jawaban hanya dalam format JSON"). Instruksi yang eksplisit ini krusial untuk meminimalisir variabilitas jawaban, mencegah halusinasi, dan menyeragamkan output untuk digunakan pada sistem spesifik yang kaku.
- *Dekomposisi Tugas*: Untuk menangani dokumen kontrak yang kompleks, pendekatan single-prompt sering kali tidak memadai. Khot et al. (2022) mengusulkan pendekatan *Decomposed Prompting*, di mana masalah besar dipecah menjadi sub-tugas yang lebih kecil dan diselesaikan secara berurutan. Dalam sistem ini, proses analisis dapat dipisahkan menjadi tahap ekstraksi fakta, tahap pencarian regulasi, dan tahap evaluasi kepatuhan, yang kemudian digabungkan kembali untuk membentuk kesimpulan akhir yang lebih robust.

II.1.2.3 Chain-of-Thought Prompting pada Kasus Hukum

Salah satu keterbatasan inheren pada LLM standar adalah kecenderungan untuk memetakan input langsung ke output secara intuitif, yang sering kali menghasilkan kesalahan logika pada tugas-tugas yang membutuhkan penalaran bertingkat. Wei et al. (2022) mengidentifikasi fenomena ini dan memperkenalkan pendekatan *Chain-of-Thought (CoT) Prompting* sebagai solusinya. Secara fundamental, CoT mengubah cara model memproses informasi dengan menginstruksikan model untuk menghasilkan serangkaian *intermediate reasoning steps* sebelum memberikan jawaban akhir. Pendekatan ini secara efektif memecah masalah kompleks menjadi

komponen-komponen yang lebih kecil dan mudah dikelola, memberikan alokasi komputasi tambahan bagi model untuk memverifikasi logika internalnya sebelum sampai pada konklusi.



Gambar II.3 Tiga Pendekatan untuk Legal judgment prediction
(Sumber: Jiang et al., 2023)

Relevansi teknik ini dalam domain hukum sangat signifikan karena struktur analisis legal yang bersifat deduktif. Jiang et al. (2023) dalam penelitiannya mengenai penalaran hukum pada LLM menyoroti bahwa CoT selaras dengan struktur silogisme hukum tradisional. Dalam implementasi sistem ini, teknik CoT diterapkan untuk memaksa model meniru proses kognitif seorang ahli hukum melalui tahapan eksplisit berikut:

- **Identifikasi Premis Mayor:** Model diinstruksikan untuk terlebih dahulu mengisolasi dan mengutip pasal regulasi yang relevan dari konteks yang diberikan oleh sistem RAG. Langkah ini memastikan bahwa analisis didasarkan pada landasan hukum yang valid.
- **Identifikasi Premis Minor:** Model kemudian mengekstrak fakta material atau klausul spesifik dari dokumen kontrak yang sedang ditinjau.
- **Reasoning:** Model melakukan proses penalaran untuk menentukan apakah fakta yang ditemukan masuk ke dalam kualifikasi aturan hukum tersebut. Di sinilah model mendeteksi adanya inkonsistensi. Urgensi keberadaan langkah ini juga terletak pada fungsinya sebagai dasar kapabilitas *post hoc verification* pada model.
- **Konklusi:** Berdasarkan sintesis dari langkah-langkah sebelumnya, model baru diizinkan untuk memberikan status kepatuhan (misalnya: Patuh, Melanggar, atau Perlu Tinjauan).

Dalam pembuatan *Chain-of-thought prompt*, Selain varian standar yang menggunakan contoh (*few-shot*), Kojima et al. (2022) menemukan bahwa kemampuan penalaran ini juga dapat dimunculkan tanpa demonstrasi contoh melalui teknik *Zero-Shot Chain-of-Thought*. Penelitian mereka menunjukkan bahwa penambahan frasa pemicu sederhana seperti "*Let's think step by step*" (Mari berpikir langkah demi langkah) pada akhir *prompt* mampu mengubah mode operasi model dari penjawab cepat menjadi penalaran lambat. Temuan ini memberikan fleksibilitas pada sistem untuk tetap melakukan analisis mendalam meskipun tidak tersedia contoh referensi yang spesifik untuk kasus tertentu.

Penerapan CoT tidak hanya meningkatkan akurasi deteksi anomali, tetapi juga memberikan elemen *Explainability*. Output yang dihasilkan model bukan sekadar label "Tidak Patuh", melainkan narasi logis yang menjelaskan mengapa ketidakpatuhan tersebut terjadi, yang sangat krusial untuk kebutuhan audit dan validasi langsung dari manusia.


II.2 Retrieval-Augmented Generation (RAG)

Meskipun LLM memiliki kemampuan linguistik yang mumpuni, penerapannya secara langsung pada domain spesifik seperti hukum menghadapi dua kendala fundamental: pengetahuan yang bersifat statis (terbatas pada tanggal pemotongan data latih) dan kecenderungan untuk menghasilkan halusinasi (menciptakan fakta yang tidak nyata). Untuk mengatasi keterbatasan ini tanpa melalui proses pelatihan ulang yang mahal, penelitian ini mengadopsi arsitektur *Retrieval-Augmented Generation* (RAG).

II.2.1 Definisi dan Arsitektur Retrieval-Augmented Generation

Retrieval-Augmented Generation (RAG) merupakan paradigma dalam pemrosesan bahasa alami yang diperkenalkan oleh Lewis et al. (2020). Paradigma ini dikembangkan untuk mengatasi dua keterbatasan fundamental pada LLM standar, yaitu pengetahuan yang bersifat statis (terbatas pada data pelatihan) dan kecenderungan halusinasi (fabrikasi fakta). RAG memecahkan masalah ini dengan menggabungkan memori parametrik (bobot internal model) dan memori non-parametrik (basis pengetahuan eksternal). Namun, RAG bukanlah sebuah arsitektur tunggal yang kaku, Gao et al. (2023) dalam surveinya mengklasifikasikan RAG ke dalam paradigma

Naive, *Advanced*, dan *Modular*, di mana setiap tahapannya memiliki variasi strategi yang dapat dipilih sesuai kebutuhan domain.



Gambar II.4 Overview Pendekatan Awal RAG

(Sumber: Lewis et al., 2020)

Tahap pertama dalam RAG adalah menemukan dokumen yang relevan (*retriever*). Tahap ini mengambil dokumen yang relevan dengan konteks x dari sumber pengetahuan tertentu sehingga didapatkan dokumen-dokumen terkait z . Keberhasilan seluruh sistem sangat bergantung pada kualitas dokumen yang ditemukan pada tahap ini. Terdapat beberapa variasi pendekatan yang umum digunakan:

- *Sparse Retrieval (Keyword-based)*: Pendekatan tradisional seperti BM25 yang mencocokkan kata kunci secara eksak antara *query* dan dokumen. Robertson dan Zaragoza (2009) menjelaskan bahwa metode ini sangat presisi untuk istilah teknis yang spesifik (misalnya, nomor regulasi "UU No. 11 Tahun 2008"). Namun, metode ini gagal menangkap hubungan semantik.
- *Dense Retrieval (Semantic-based)*: Menggunakan *vector embeddings* untuk memetakan teks ke ruang vektor. Karpukhin et al. (2020) menunjukkan metode ini unggul dalam menangkap kesamaan makna meskipun tidak ada kata yang sama persis. Ini sangat krusial untuk kasus di mana pengguna mendeskripsikan situasi pelanggaran tanpa menggunakan istilah hukum yang baku.

- *Hybrid Search*: Menggabungkan kekuatan *Sparse* dan *Dense Retrieval*. Metode ini melakukan pencarian kata kunci dan pencarian vektor secara paralel, kemudian menggabungkan hasilnya menggunakan algoritma fusi peringkat seperti *Reciprocal Rank Fusion* (RRF). Dalam konteks hukum, pendekatan *hybrid* sering kali menjadi standar emas karena mampu menangkap nomor pasal yang spesifik sekaligus memahami konteks naratif kasus (Cormack et al., 2009).
- *Query Transformation* (HyDE): Gao et al. (2022) memperkenalkan *Hypothetical Document Embeddings* (HyDE). Pada cara ini, sistem meminta LLM untuk membuat "dokumen jawaban hipotesis" terlebih dahulu, kemudian vektor dari dokumen hipotesis tersebut yang digunakan untuk pencarian. Variasi ini membantu menjembatani kesenjangan linguistik antara *query* pengguna yang singkat dengan dokumen regulasi yang formal.

Setelah dokumen kandidat ditemukan, tidak semua dokumen tersebut langsung dimasukkan ke LLM. Terdapat langkah optimasi lanjutan yang disebut *Post-Retrieval Processing*:

- *Reranking* (Peringkat Ulang): Dokumen hasil pencarian awal dinilai ulang menggunakan model *Cross-Encoder* yang lebih akurat namun komputasinya lebih berat. Model ini membaca *query* dan dokumen secara bersamaan untuk memberikan skor relevansi yang presisi. Teknik ini memastikan bahwa hanya dokumen yang benar-benar relevan yang masuk ke *context window* LLM, mengurangi *noise* yang dapat membingungkan model (Reimers & Gurevych, 2019).
- *Context Selection/Compression*: Jika dokumen yang ditemukan terlalu panjang, teknik seperti *summarization* atau ekstraksi paragraf kunci diterapkan untuk memadatkan informasi tanpa menghilangkan esensi hukumnya, memastikan penggunaan token yang efisien.

Pada tahap akhir (*generator*), cara LLM memanfaatkan konteks juga memiliki variasi arsitektur:

- *One-Shot RAG*: Pola standar di mana dokumen diambil sekali dan jawaban langsung dihasilkan.

- *Iterative & Self-RAG*: Asai et al. (2024) memperkenalkan konsep *Self-Reflective RAG*, di mana model dilatih untuk mengkritik outputnya sendiri. Jika model merasa informasi yang diambil kurang lengkap atau jawaban yang dihasilkan tidak didukung oleh dokumen, model akan memicu proses retrieval ulang secara mandiri. Variasi ini sangat relevan untuk audit kontrak yang mendalam, di mana satu temuan mungkin memerlukan pengecekan silang ke regulasi lain secara berantai.

II.2.2 Strategi Text Chunking

Dalam arsitektur RAG, *Text Chunking* atau segmentasi dokumen merupakan tahapan kritis yang menjembatani kesenjangan antara panjang dokumen asli (misalnya kontrak setebal 50 halaman) dengan keterbatasan *context window* pada model *embedding* dan LLM. Merola dan Singh (2025) dalam penelitiannya yang berjudul "*Reconstructing Context: Evaluating Advanced Chunking Strategies for Retrieval-Augmented Generation*" menyoroti bahwa segmentasi tradisional sering kali memecah koherensi semantik, menyebabkan hilangnya konteks global yang krusial untuk pengambilan keputusan hukum. Oleh karena itu, pemilihan strategi *chunking* tidak sekadar masalah teknis pemotongan teks, melainkan strategi preservasi makna.

Berdasarkan tinjauan literatur, strategi chunking dapat diklasifikasikan menjadi pendekatan *Early Chunking* (Tradisional) dan pendekatan *Advanced* yang meliputi *Late Chunking* dan *Contextual Retrieval*.

1. Early Chunking


Pendekatan ini adalah metode standar dalam mayoritas sistem RAG saat ini. Dokumen dibagi menjadi segmen-segmen kecil sebelum proses konversi ke vektor (*embedding*).

1. *Fixed-Size Chunking*: Dokumen dipotong berdasarkan jumlah karakter atau token yang tetap (misalnya 512 token) dengan overlap tertentu. Meskipun efisien secara komputasi, metode ini bersifat agnostik terhadap struktur kalimat, sehingga berisiko memotong penjelasan pasal di tengah kalimat.
2. *Semantic Chunking*: Menggunakan model pendukung (seperti BERT atau *Jina-Segmenter*) untuk mendeteksi perpindahan topik atau batas semantik

sebelum memotong teks. Meskipun lebih baik daripada *fixed-size*, metode ini tetap memproses setiap potongan secara independen, sehingga potongan tersebut kehilangan akses terhadap informasi di bagian lain dokumen.

2. *Late Chunking*

Diperkenalkan oleh Günther et al. (2024), *Late Chunking* menawarkan perubahan paradigma dengan menunda proses segmentasi. Alih-alih memotong teks di awal, metode ini memproses seluruh dokumen terlebih dahulu melalui model *embedding* yang mendukung konteks panjang (hingga 8192 token atau lebih).



Gambar II.5 Perbandingan Mekanisme Early Chunking vs Late Chunking
(Sumber: Merola dan Singh, 2025)

Perbandingan antara *early chunking* dan *late chunking* dapat dilihat pada gambar II.5. Lebih detailnya, mekanismenya adalah sebagai berikut:

1. Model *embedding* menghasilkan representasi vektor untuk setiap token di seluruh dokumen.
2. Sistem kemudian menggunakan isyarat batas (*boundary cues*) untuk mengelompokkan vektor-vektor token tersebut menjadi vektor *chunk*.
3. Dilakukan *mean pooling* pada kelompok vektor tersebut untuk mendapatkan satu *embedding* final per *chunk*.

Keunggulan utama metode ini adalah setiap vektor chunk dikondisikan oleh seluruh isi dokumen (*bidirectional attention* terhadap seluruh teks), sehingga makna global tetap terjaga meskipun teks telah disegmentasi.

3. *Contextual Retrieval*

Dikembangkan oleh Anthropic (2024), metode ini mengatasi masalah hilangnya konteks dengan cara menambahkan informasi secara eksplisit. Sebelum proses embedding, setiap chunk diproses oleh LLM untuk menghasilkan ringkasan singkat atau konteks yang menjelaskan posisi chunk tersebut dalam dokumen utuh. Ringkasan ini kemudian ditempelkan pada teks asli chunk. Contoh implementasinya jika sebuah chunk hanya berisi "Pihak Kedua wajib membayar denda 5%", LLM akan menambahkan konteks "Dalam Perjanjian Sewa Menyewa No. 123 antara PT A dan PT B, terkait keterlambatan pembayaran...". Hal ini membuat chunk tersebut dapat berdiri sendiri (*self-contained*) dan lebih mudah ditemukan oleh sistem pencarian.

II.3 Model Embedding

Model *embedding* teks merupakan komponen fundamental dalam sistem *Retrieval-Augmented Generation* yang bertugas mengubah teks menjadi representasi vektor numerik berdimensi tetap. Vektor ini dirancang sedemikian rupa sehingga teks dengan makna serupa akan menempati posisi yang berdekatan dalam ruang vektor berdimensi tinggi, sementara teks dengan makna berbeda akan berjauhan (Reimers & Gurevych, 2019). Dengan representasi ini, pencarian informasi tidak lagi bergantung pada kecocokan kata kunci secara harfiah, melainkan pada kedekatan makna yang umumnya diukur menggunakan metrik seperti *cosine similarity*.

Berbeda dari pendekatan sparse seperti TF-IDF atau BM25 yang merepresentasikan teks sebagai *sparse vector* berbasis frekuensi kata, model *embedding* modern dibangun di atas arsitektur *Transformer* dan dilatih melalui teknik *contrastive learning* agar mampu menangkap hubungan semantik yang lebih dalam. Kualitas model *embedding* menjadi sangat menentukan pada sistem RAG karena tahap retrieval berbasis vektor merupakan *upper bound* kinerja sistem secara keseluruhan. Dokumen yang gagal ditemukan pada tahap ini tidak akan pernah sampai ke LLM untuk dianalisis.

II.3.1 M3-Embedding (BGE-M3)

Model embedding teks yang dikenal juga sebagai BGE-M3 ini diperkenalkan oleh Chen et al. (2024) dalam "*BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*". Model ini dirancang dengan versatilitas pada tiga aspek (*multi-linguality*, *multi-functionality*, dan *multi-granularity*), yang membuatnya sangat sesuai untuk sistem yang memerlukan information retrieval. Berikut merupakan rincian fitur-fitur utama yang disediakan:

1. *Multi-Linguality*: BGE-M3 mendukung lebih dari 100 bahasa termasuk Bahasa Indonesia, sehingga mampu menangani pencarian baik dalam satu bahasa maupun lintas bahasa.
2. *Multi-Functionality*: Memiliki tiga fungsionalitas yang umumnya memerlukan model terpisah, yakni *dense retrieval*, *sparse retrieval*, dan *multi-vector retrieval*. Ketiganya dapat digunakan secara terpisah maupun digabungkan dalam *hybrid retrieval*.
3. *Multi-Granularity*: Model ini mampu memproses masukan dengan granularitas yang beragam, mulai dari teks pendek hingga dokumen panjang dengan dukungan konteks hingga 8192 token.

II.3.2 Jina-Embeddings-v3

Model jina-embeddings-v3 diperkenalkan oleh Sturua et al. (2024) sebagai model *embedding* teks dengan 570 juta parameter yang dirancang untuk tugas *retrieval* multibahasa dan konteks panjang, dengan dukungan masukan hingga 8192 token. Karakteristik yang membedakan model ini dari pendekatan sebelumnya adalah penggunaan sejumlah adapter *Low-Rank Adaptation* (LoRA). Alih-alih menghasilkan satu embedding generik untuk semua keperluan,

Jina-embeddings-v3 menyisipkan adapter LoRA yang sesuai ke dalam setiap lapisan *Transformer* berdasarkan jenis tugas yang dijalankan, mencakup *query-document retrieval*, *clustering*, *classification*, dan *text matching*.

Selain itu, jina-embeddings-v3 mengintegrasikan teknik *Matryoshka Representation Learning* yang memungkinkan dimensi embedding dipangkas secara fleksibel tanpa penurunan kinerja yang berarti, sehingga memberikan keseimbangan antara efisiensi penyimpanan dan akurasi. Pada evaluasi benchmark MTEB, model ini dilaporkan mengungguli model embedding proprietary dari OpenAI dan Cohere pada tugas berbahasa Inggris serta melampaui multilingual-e5-large-instruct pada tugas multibahasa (Sturua et al., 2024).

Perbedaan fundamental antara BGE-M3 dan jina-embeddings-v3 terletak pada strategi *pooling* yang digunakan untuk mengagregasi representasi token menjadi satu vektor embedding tunggal. BGE-M3 mengandalkan representasi pada token khusus [CLS] (*CLS pooling*) sebagai ringkasan makna seluruh masukan, sedangkan jina-embeddings-v3 mengikuti pendekatan Sentence-BERT dengan menerapkan *mean pooling*, yaitu merata-ratakan vektor seluruh token keluaran menjadi satu representasi (Sturua et al., 2024). Perbedaan ini berimplikasi langsung pada perilaku kedua model. Sturua et al. (2024) mencatat bahwa kinerja BGE-M3 pada teks panjang berbeda dari jina-embeddings-v3, yang sebagian disebabkan oleh perbedaan strategi *pooling* di samping perbedaan data latih.

II.3.3. Reranking

Reranking atau peringkat ulang merupakan tahap optimasi *post-retrieval* yang bertujuan menyaring dan menyusun ulang dokumen kandidat hasil pencarian awal agar dokumen yang benar-benar relevan menempati posisi teratas. Kebutuhan akan tahap ini muncul dari keterbatasan arsitektur *bi-encoder* yang umum digunakan pada retrieval berbasis *embedding*. Pada *bi-encoder*, kueri dan dokumen di-embedding secara terpisah lalu dibandingkan kedekatannya. Pendekatan ini sangat efisien untuk pencarian berskala besar namun mengorbankan presisi karena kueri dan dokumen tidak pernah "saling melihat" selama proses encoding (Reimers & Gurevych, 2019).

Sebaliknya, *reranker* umumnya diimplementasikan menggunakan arsitektur *cross-encoder*. Berbeda dari *bi-encoder*, *cross-encoder* memproses pasangan kueri dan dokumen secara

bersamaan dalam satu masukan, sehingga mekanisme *self-attention* dapat memodelkan interaksi langsung antara setiap token kueri dengan setiap token dokumen. Nogueira dan Cho (2019) menunjukkan bahwa penerapan *cross-encoder* berbasis BERT untuk *passage re-ranking* mampu meningkatkan kualitas peringkat secara signifikan dibandingkan metode sebelumnya. Konsekuensinya, *cross-encoder* menghasilkan skor relevansi yang jauh lebih presisi, namun dengan biaya komputasi yang jauh lebih tinggi karena setiap pasangan kueri-dokumen harus diproses secara individual dan tidak dapat dihitung sebelumnya (*precomputed*).

Karena alasan inilah reranker tidak digunakan untuk memindai seluruh basis data, melainkan diterapkan pada arsitektur dua tahap: *bi-encoder* terlebih dahulu mengambil sejumlah kandidat teratas secara cepat, kemudian *cross-encoder* menilai ulang kandidat tersebut untuk menghasilkan peringkat akhir.

II.4 Metrik Evaluasi Sistem RAG

Evaluasi sistem *Retrieval-Augmented Generation* (RAG) menghadirkan kompleksitas yang tidak dapat diselesaikan dengan metrik evaluasi teks konvensional seperti BLEU atau ROUGE. Metrik-metrik tersebut hanya mengukur tumpang tindih kata antara prediksi dan referensi, namun gagal menangkap akurasi faktual dan konsistensi logika yang menjadi prioritas utama dalam analisis hukum. Oleh karena itu, penelitian ini mengadopsi pendekatan evaluasi yang memisahkan penilaian antara komponen *retrieval* (kemampuan sistem menemukan dokumen) dan komponen *generation* (kemampuan model menyusun analisis).

II.4.1 Evaluasi Komponen Retrieval

Kualitas dokumen yang diambil dari basis data vektor menjadi penentu batas atas kinerja sistem secara keseluruhan. Mengacu pada metodologi evaluasi yang diterapkan oleh Merola dan Singh (2025) dalam studi komparasi strategi *chunking*, penilaian komponen retriever difokuskan pada aspek peringkat dan relevansi dokumen. Mengingat sistem RAG biasanya hanya mengambil sejumlah kecil dokumen teratas (*Top-K*) untuk dimasukkan ke dalam *context window* LLM, posisi dokumen relevan dalam daftar hasil pencarian menjadi sangat vital. Tiga metrik standar industri berikut digunakan untuk mengukur efektivitas *retrieval*:

- *Normalized Discounted Cumulative Gain* (NDCG):

Diperkenalkan oleh Järvelin dan Kekäläinen (2002), metrik ini mengukur kegunaan dokumen berdasarkan posisinya dalam daftar peringkat. Berbeda dengan metrik biner yang hanya menilai ada/tidaknya dokumen, NDCG memberikan bobot skor yang lebih tinggi jika dokumen yang sangat relevan muncul di urutan teratas. Dalam konteks RAG hukum, metrik ini sangat krusial karena LLM cenderung memberikan perhatian lebih pada informasi yang muncul di awal konteks, sebuah fenomena yang dikenal sebagai *primacy bias* (Liu et al., 2023). Skor NDCG yang tinggi menjamin bahwa pasal regulasi yang paling tepat disajikan sebagai prioritas utama kepada model.

- *Mean Average Precision* (MAP):

MAP digunakan untuk mengukur stabilitas kinerja sistem di seluruh kueri yang berbeda. Metrik ini menghitung rata-rata dari skor *Average Precision* (AP) untuk setiap kueri, di mana AP mempertimbangkan presisi pada setiap posisi dokumen relevan yang ditemukan. Penggunaan MAP bertujuan untuk mengkuantifikasi seberapa efektif model retrieval bekerja secara konsisten dalam berbagai skenario kasus hukum yang beragam, memastikan sistem tidak bias terhadap jenis pasal tertentu saja.

- F1-Score:

F1-Score didapat dari *precision* dan *recall*, metrik ini memberikan gambaran keseimbangan kinerja sistem. Dalam audit kontrak, keseimbangan ini penting untuk meminimalkan *false negatives* (kegagalan mengambil pasal yang relevan) sekaligus menekan *false positives* (pengambilan pasal tidak relevan yang menjadi noise).

Selain tiga metrik di atas, terdapat metrik terkait retrieval yang diperkenalkan oleh kerangka RAGAS (*Retrieval Augmented Generation Assessment*) (Es et al., 2023), yaitu *context relevance*. Metrik ini mengukur seberapa terfokus konteks yang diambil $c(q)$ terhadap suatu kueri q , dengan prinsip bahwa konteks yang ideal seharusnya hanya memuat informasi yang benar-benar diperlukan untuk menjawab kueri dan seminimal mungkin mengandung informasi yang mubazir. Pemfokusan ini penting karena konteks yang terlalu panjang tidak hanya membebani biaya komputasi LLM, tetapi juga menurunkan efektivitas model dalam memanfaatkan informasi, terutama yang berada di tengah konteks (fenomena *lost-in-the-middle*) (Es et al., 2023; Liu et al., 2023).

Berbeda dari metrik retrieval klasik seperti NDCG atau MAP yang memerlukan label relevansi acuan, context relevance dihitung secara otomatis tanpa jawaban referensi (*reference-free*) dengan memanfaatkan LLM sebagai evaluator. Mekanismenya berlangsung dalam dua tahap. Pertama, diberikan kueri q beserta konteksnya $c(q)$, LLM diinstruksikan untuk mengekstrak himpunan bagian kalimat S_{ext} dari konteks tersebut yang dinilai krusial untuk menjawab kueri. Kedua, skor dihitung sebagai rasio antara jumlah kalimat yang diekstrak terhadap total jumlah kalimat dalam konteks, sebagaimana dirumuskan pada Persamaan berikut.

$$CR = \frac{\text{number of extracted sentences}}{\text{total number of sentences in } c(q)} \quad (2.1)$$

Dengan formulasi pada persamaan 2.1, konteks yang sepenuhnya relevan akan menghasilkan skor mendekati 1, sedangkan konteks yang banyak memuat kalimat tidak relevan akan menghasilkan skor yang rendah. Dalam penelitian ini, *context relevance* digunakan sebagai metrik utama untuk mengukur kualitas tahap *retrieval* pada kedua *pipeline* analisis.

II.4.2 Evaluasi Komponen Generasi

Tantangan kini beralih pada kemampuan LLM untuk mensintesis informasi tersebut menjadi analisis yang akurat dan bebas halusinasi. Untuk tahap ini, penelitian mengadopsi kerangka kerja RAGAS (*Retrieval Augmented Generation Assessment*) yang diperkenalkan oleh Es et al. (2023). RAGAS menggunakan paradigma *reference-free evaluation*, di mana kualitas output dinilai tanpa memerlukan jawaban referensi manusia, melainkan menggunakan LLM sebagai evaluator (*LLM-as-a-Judge*).

- *Faithfulness*

Metrik ini mengukur konsistensi faktual dari jawaban yang dihasilkan ($a_s(q)$) terhadap konteks yang diberikan ($c(q)$). Tujuannya adalah untuk mendeteksi halusinasi dan memastikan bahwa model tidak memfabrikasi informasi yang tidak terdapat dalam dokumen konteks. Sebuah jawaban dinilai *faithful* jika klaim-klaim yang dibuat di dalamnya dapat disimpulkan sepenuhnya dari konteks yang diambil.

Mekanisme perhitungan skor Faithfulness melibatkan dua langkah:

1. Ekstraksi Pernyataan: Menggunakan LLM untuk memecah jawaban yang panjang menjadi himpunan pernyataan atomik.

$$S = \{s_1, s_2, \dots, s_n\} \quad (2.2)$$

2. Verifikasi: Untuk setiap pernyataan s_i LLM memverifikasi apakah pernyataan tersebut sesuai dengan suatu konteks $c(q)$.

Skor Faithfulness (F) kemudian dihitung sebagai rasio antara jumlah pernyataan yang terverifikasi ($|V|$) dengan total jumlah pernyataan yang diekstrak ($|S|$):

$$F = \frac{|V|}{|S|} \quad (2.3)$$

Di mana V adalah himpunan pernyataan yang didukung oleh konteks. Skor ini berkisar antara 0 hingga 1, di mana skor 1 menunjukkan bahwa seluruh analisis hukum yang dihasilkan model berakar kuat pada teks regulasi yang ditemukan.

- *Answer Relevance*

Metrik ini mengukur seberapa relevan jawaban yang dihasilkan terhadap pertanyaan atau instruksi awal pengguna (q), terlepas dari kebenaran faktanya. Metrik ini bertujuan untuk memberikan sanksi jawaban yang tidak lengkap, berlebihan, atau tidak menjawab inti permasalahan yang diajukan. Es et al. (2023) menegaskan bahwa metrik ini tidak mengukur faktualitas, melainkan ketepatan respons terhadap intensi pertanyaan.

Mekanisme perhitungan skor *Answer Relevance* dilakukan dengan cara merekonstruksi pertanyaan potensial dari jawaban yang dihasilkan:

1. LLM diminta untuk menghasilkan n pertanyaan potensial q_i berdasarkan jawaban $a_s(q)$ yang diberikan.
2. Sistem kemudian menghitung kemiripan semantik antara pertanyaan asli q dengan setiap pertanyaan yang dihasilkan q_i menggunakan *cosine similarity* pada representasi *embedding* mereka.

Skor Answer Relevance (AR) didefinisikan sebagai rata-rata dari skor kemiripan tersebut:

$$AR = \frac{1}{n} \sum_{i=1}^n sim(q, q_i) \quad (2.4)$$

Di mana $sim(q, q_i)$ adalah cosine similarity antara *embedding* pertanyaan asli dan pertanyaan hasil generasi. Skor yang tinggi menunjukkan bahwa jawaban tersebut secara spesifik membahas apa yang ditanyakan, yang sangat penting dalam audit kontrak untuk memastikan model tidak memberikan penjelasan hukum umum yang tidak relevan dengan klausul yang ditanyakan.

II.5 Penelitian Terkait

Bagian ini berisi penjelasan tentang penelitian-penelitian terkait yang sudah pernah dilakukan. Tujuannya adalah mendapatkan gambaran yang lebih luas terkait domain permasalahan dan inovasi-inovasi yang pernah dikembangkan.

II.5.1 LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models

LegalBench diperkenalkan oleh Guha et al. (2023) sebagai sebuah *benchmark* kolaboratif berskala besar yang bertujuan untuk mengukur kemampuan penalaran hukum pada *large language model* (LLM). *Benchmark* ini dibangun melalui proses lintas disiplin yang melibatkan pakar hukum dan ilmuwan komputer. Dari sisi penyusunan, *LegalBench* menghimpun 162 tugas berbeda yang diekstraksi dari 36 sumber data, mencakup teks undang-undang (statutes), putusan pengadilan (judicial opinions), hingga dokumen kontrak.

Kontribusi utama dari *LegalBench* adalah pengelompokan tugas-tugas tersebut berdasarkan taksonomi penalaran hukum yang umum digunakan oleh praktisi, yakni kerangka IRAC (Issue, Rule, Application, dan Conclusion), ditambah dengan aspek interpretasi dan pemahaman retorik. Karena dirancang langsung oleh para profesional, tugas-tugas ini diklaim merepresentasikan kemampuan penalaran yang benar-benar berguna secara praktis maupun menarik secara akademis. Keenam kategori penalaran yang diukur memiliki rincian sebagai berikut:

1. *Issue-spotting*: Menguji kemampuan model dalam mengidentifikasi masalah hukum yang muncul dari narasi fakta.
2. *Rule-recall*: Berfokus pada kemampuan model dalam memanggil atau mengingat kembali pasal dan aturan hukum yang relevan secara akurat.
3. *Rule-application*: Menuntut model untuk menjelaskan logika penerapan suatu aturan hukum pada sekumpulan fakta.
4. *Rule-conclusion*: Mengevaluasi ketepatan model dalam memprediksi hasil akhir atau kesimpulan hukum berdasarkan aturan yang telah ditentukan.
5. *Interpretation*: Menguji pemahaman model terhadap makna tekstual dari klausul kontrak atau dokumen hukum yang rumit dan penuh terminologi spesifik.
6. *Rhetorical-analysis*: Mengevaluasi kemampuan model dalam memahami fungsi dan struktur argumen dalam dokumen hukum.

Evaluasi di atas dilakukan pada 20 model LLM dengan berbagai ukuran parameter dan ini memberikan hasil yang variatif. Selain itu, dilakukan juga perbandingan penggunaan dengan bahasa sehari-hari (*plain language*) dan penggunaan bahasa teknis (*technical language*). Hasil percobaan variasi bahasa pada *prompt* menunjukkan penggunaan bahasa sehari-hari memberikan performa yang cenderung memberikan hasil yang lebih baik pada sebagian besar percobaan.

II.5.2 LegalBench-RAG: A Benchmark for Retrieval-Augmented Generation in the Legal Domain

Penelitian oleh Pipitone dan Alami yang dilakukan pada tahun 2024 ini memperkenalkan tentang LegalBench-RAG, sebuah benchmark untuk menilai efektivitas komponen retrieval pada sistem RAG yang digunakan pada domain hukum. Penelitian ini muncul untuk mengisi kekosongan yang diberikan oleh LegalBench (Guha et al., 2023) yang berfokus pada proses *generation*.

LegalBench-RAG menggunakan gabungan empat dataset tanya jawab hukum yakni *Privacy Question Answering* (PrivacyQA), *Contract Understanding Atticus Dataset* (CUAD), *Mergers and Acquisitions Understanding Dataset* (MAUD), dan *Contract Natural Language Inference* (ContractNLI). Fokus dari *benchmarking* ini adalah “*precise retrieval*”, mengambil segmen teks seminimal mungkin namun sangat relevan, hal ini terkait dengan penghematan konteks pada LLM untuk meminimalkan latensi dan kemungkinan halusinasi. Penelitian dilanjutkan dengan

membandingkan *precision* dan *recall* dari metode *chunking* naif dan *Recursive Character Text Splitter* (RCTS), keduanya dicoba dengan dan tanpa *reranker*. Hasil menunjukkan nilai bervariasi tergantung dengan metode yang digunakan, mengindikasikan adanya pengaruh metode *chunking* pada efektivitas proses *retrieval*.

II.5.3 Reconstructing Context: Evaluating Advanced Chunking Strategies for Retrieval-Augmented Generation

Untuk menentukan strategi segmentasi (*chunking*) yang paling optimal bagi sistem RAG, Merola dan Singh (2025) melakukan serangkaian eksperimen yang membandingkan pendekatan *Early Chunking*, *Late Chunking*, dan *Contextual Retrieval*. Evaluasi dilakukan menggunakan empat model *embedding* terkemuka, yaitu Jina-V3, Jina-ColBERT-V2, Stella-V5, dan BGE-M3, dengan model bahasa Phi-3.5-mini-instruct sebagai komponen generasi. Dua dataset digunakan secara terpisah sesuai dengan aspek yang dievaluasi. Tahap *retrieval* diuji menggunakan dataset NFCorpus, sebuah dataset di domain medis yang dicirikan oleh dokumen dengan panjang rata-rata yang besar, sehingga relevan untuk menguji kemampuan strategi *chunking* dalam mempertahankan konteks pada dokumen panjang. Karena keterbatasan memori perangkat (eksperimen dijalankan pada satu GPU Nvidia RTX 4090 berkapasitas 24 GB), evaluasi *retrieval* untuk perbandingan *contextual retrieval* hanya menggunakan subset 20% dari keseluruhan NFCorpus. Sementara itu, tahap generasi (*question answering*) diuji menggunakan dataset MSMarco, yang dicirikan oleh *passage* pendek. Perbedaan karakteristik kedua dataset inilah yang kemudian menjelaskan sebagian temuan, misalnya keunggulan *early chunking* pada MSMarco yang disebabkan oleh sifat *passage*-nya yang pendek sehingga keuntungan "konteks global" dari *late chunking* menjadi tidak relevan.

Kinerja sistem diukur menggunakan tiga metrik utama dalam Information Retrieval:

- NDCG@k (*Normalized Discounted Cumulative Gain*): Mengukur kualitas peringkat dokumen yang diambil, dengan memberikan bobot lebih tinggi pada dokumen relevan yang muncul di posisi teratas (k).

- MAP@k (*Mean Average Precision*): Merepresentasikan rata-rata presisi di seluruh kueri, memberikan gambaran umum mengenai konsistensi sistem dalam mengambil informasi yang relevan.
- F1-Score@k: Rata-rata harmonik antara presisi dan recall, memberikan keseimbangan evaluasi antara ketepatan dan kelengkapan informasi yang diambil.

Berikut adalah analisis mendalam berdasarkan hasil eksperimen:

1. Perbandingan *Early* vs. *Late Chunking*

Berdasarkan hasil dalam studi tersebut, kinerja *late chunking* menunjukkan hasil yang bervariasi tergantung pada arsitektur model embedding yang digunakan. Pada model Jina-V3, strategi Late Chunking memberikan peningkatan marjinal namun konsisten dibandingkan *early chunking* pada *dataset* NFCorpus. Namun, anomali signifikan terlihat pada model BGE-M3, di mana penerapan *late chunking* justru menurunkan kinerja secara drastis.

Model	Chunk	Segm	Length	NDCG@5	MAP@5	F1@5	NDCG@10	MAP@10	F1@10
Stella-V5	Early	Fix-size	512	0.443	0.137	0.226	0.414	0.161	0.247
	Late	Fix-size	512	0.445	0.133	0.225	0.410	0.158	0.242
Jina-V3	Early	Fix-size	512	0.374	0.107	0.186	0.346	0.127	0.204
	Late	Fix-size	512	0.380	0.103	0.185	0.354	0.125	0.210
	Early	Jina-Sem	-	0.377	0.111	0.192	0.353	0.130	0.210
	Late	sim-Qwen	-	0.384	0.105	0.185	0.356	0.126	0.206
	Late	top-Qwen	-	0.383	0.102	0.179	0.351	0.122	0.203
Jina-V2	Early	Fix-size	512	0.261	0.064	0.124	0.237	0.075	0.137
	Late	Fix-size	512	0.280	0.069	0.125	0.255	0.081	0.146
	Early	Jina-Sem	-	0.294	0.079	0.144	0.269	0.092	0.158
	Late	sim-Qwen	-	0.278	0.071	0.130	0.253	0.083	0.146
	Late	top-Qwen	-	0.279	0.070	0.135	0.254	0.081	0.147
BGE-M3	Early	Fix-size	512	0.246	0.059	0.120	0.225	0.069	0.130
	Late	Fix-size	512	0.070	0.010	0.029	0.067	0.013	0.038
	Early	Jina-Sem	-	0.260	0.066	0.122	0.240	0.079	0.144
	Late	sim-Qwen	-	0.091	0.015	0.038	0.081	0.018	0.045
	Late	top-Qwen	-	0.110	0.019	0.044	0.097	0.022	0.048

Gambar II.6 Perbandingan Early vs Late Retriever pada NFCorpus

(Sumber: Merola dan Singh, 2025)

Fenomena ini mengindikasikan bahwa *late chunking* bukanlah solusi universal. Efektivitasnya sangat bergantung pada kemampuan model *embedding* dasar untuk menangani konteks panjang sebelum dilakukan *pooling*.

Lebih lanjut, pada evaluasi dataset MSMarco, pendekatan tradisional *early chunking* justru mengungguli *late chunking* secara signifikan pada model Stella-V5. Hal ini kemungkinan disebabkan oleh karakteristik dataset MSMarco yang berupa *short passages*, sehingga keuntungan "konteks global" dari *Late Chunking* menjadi tidak relevan atau bahkan menimbulkan *noise*.

Model	Chunk	Segm	Length	NDCG@5	MAP@5	F1@5	NDCG@10	MAP@10	F1@10
Stella-V5	Early	Fix-size	512	0.630	0.501	0.019	0.632	0.502	0.011
	Late	Fix-size	512	0.503	0.340	0.018	0.505	0.341	0.010

Gambar II.7 Perbandingan Early vs Late Retriever pada MSMarco

(Sumber: Merola dan Singh, 2025)

2. Perbandingan *Late Chunking* vs. *Contextual Retrieval*

Eksperimen kunci untuk penelitian ini juga terdapat pada perbandingan antara *late chunking* dan *contextual retrieval*. Sebagaimana hasil yang ditunjukkan pada hasil percobaan oleh Merola dan Singh (2025), pendekatan *contextual retrieval* secara konsisten mengungguli *late chunking* pada seluruh metrik evaluasi utama menggunakan model Jina-V3 pada subset dataset NFCorpus.

Method	NDCG@5	MAP@5	F1@5	NDCG@10	MAP@10	F1@10
Late	0.309	0.143	0.202	0.294	0.160	0.192
Contextual	0.317	0.146	0.206	0.308	0.166	0.202

Gambar II.8 Perbandingan Late Chunking vs Contextual Retrieval pada NFCorpus

(Sumber: Merola dan Singh, 2025)

Analisis hasil ini menunjukkan beberapa temuan:

- Superioritas Akurasi: *contextual retrieval* mencapai skor NDCG@10 sebesar 0.308, lebih tinggi dibandingkan *late chunking* (0.294). Ini membuktikan bahwa augmentasi konteks secara eksplisit (menambahkan ringkasan dokumen ke setiap chunk) lebih efektif dalam menjaga makna semantik dibandingkan sekadar memproses embedding secara global.

- *Trade-off* Komputasi: Meskipun *contextual retrieval* unggul dalam akurasi, Merola dan Singh mencatat bahwa metode ini memerlukan sumber daya komputasi yang jauh lebih besar. Proses pembuatan konteks untuk setiap chunk menggunakan LLM memakan waktu dan memori GPU yang signifikan.

BAB III ANALISIS MASALAH DAN RANCANGAN SOLUSI

Pada bab ini, dijelaskan mengenai analisis masalah serta desain solusi yang diusulkan dalam penelitian. Pembahasan diawali dengan gambaran umum sistem, diikuti oleh penjabaran analisis masalah, dan ditutup dengan rancangan solusi yang meliputi bahasan mengenai data, rancangan implementasi setiap modul, hingga rancangan eksperimen.

III.1 Deskripsi Aplikasi

Berdasarkan masalah yang telah dirumuskan pada Bab 1, penelitian akan difokuskan dalam mengembangkan subsistem berbasis *large language model* (LLM) dan *retrieval-augmented generation* (RAG) yang berperan sebagai modul analisis dalam sistem besar *capstone*.

Subsistem ini terdiri dari dua *pipeline* analisis yang saling melengkapi dalam menjawab rumusan masalah. *Pipeline* pertama merupakan *pipeline* analisis kepatuhan yang menjawab permasalahan kedua mengenai analisis kepatuhan kontrak terhadap regulasi. *Pipeline* kedua merupakan rangkaian proses yang disusun untuk menganalisis entitas, menjawab permasalahan pertama sembari menjawab pertanyaan kedua lewat menganalisis kepatuhan yang berkaitan dengan entitas. Kedua *pipeline* ini didukung oleh subsistem yang bertugas untuk mengisi basis data dengan peraturan.

Subsistem ini akan mendapatkan regulasi dan dokumen kontrak dari subsistem lain dari *capstone* yang bertugas untuk melakukan *optical character recognition* (OCR) dan ekstraksi entitas. Hasil dua *pipeline* utama juga akan menjadi sumber masukan bagi modul lain pada *capstone*, yakni modul *agentic AI*.

III.2 Analisis Masalah

Pengembangan sistem analisis kontrak otomatis menghadapi berbagai tantangan teknis yang unik, terutama karena karakteristik dokumen hukum yang panjang, saling terkait, dan membutuhkan presisi tinggi. Masalah mendasar tidak hanya terletak pada pemahaman bahasa, tetapi juga pada arsitektur sistem yang harus menjembatani kesenjangan antara efektivitas penggunaan token pada model dengan volume data regulasi yang masif.


Berdasarkan tinjauan terhadap kebutuhan sistem dan batasan teknologi saat ini, identifikasi masalah dirumuskan sebagai berikut:

Tabel III.1 Tabel Masalah

ID	Masalah
M-01	Limitasi Ukuran <i>Context Window</i> Deteksi Inkonsistensi pada Dokumen Bervolume Besar: Dokumen kontrak publik memiliki struktur yang kompleks dan panjang. Mencari inkonsistensi secara manual sangat rentan kesalahan, sementara model bahasa standar sering gagal mempertahankan perhatian pada dokumen dengan panjang token yang besar.
M-02	Fragmentasi Konteks akibat Keterbatasan <i>Context Window</i> : Proses pemecahan dokumen (<i>chunking</i>) yang diperlukan untuk memuat teks ke dalam memori model sering kali memutus hubungan semantik antara pasal dan konteks besar pada dokumen peraturan tempat pasal itu dijelaskan. Hal ini berisiko menghilangkan konteks krusial yang diperlukan untuk interpretasi hukum yang benar.
M-03	Tantangan <i>Retrieval</i> pada <i>Query</i> dan <i>Database</i> Berukuran Besar: Berbeda dengan pencarian umum, kasus ini melibatkan kueri berupa draf kontrak yang panjang untuk dicocokkan dengan basis data regulasi yang juga masif. Menemukan dokumen peraturan yang spesifik dan relevan menjadi sulit karena tingginya <i>noise</i> dan kompleksitas pencarian.
M-04	Risiko Halusinasi Model pada Teks Panjang: Model generatif memiliki kecenderungan untuk halusinasi karena mengabaikan informasi yang berada di tengah urutan input yang panjang (<i>lost-in-the-middle</i>) dan memfabrikasi fakta ketika tidak memiliki landasan referensi yang kuat.
M-05	Ketiadaan Mekanisme Evaluasi Terukur: Hasil analisis yang dihasilkan oleh AI sulit divalidasi secara objektif tanpa adanya metrik otomatis. Ketiadaan data validasi membuat sulitnya pengukuran apakah kutipan pasal yang digunakan relevan dan apakah kesimpulan yang diambil konsisten dengan fakta yang ditemukan.

III.3 Gambaran Umum Solusi

Untuk menjawab rumusan masalah yang telah diuraikan, penelitian ini merancang dan mengimplementasikan subsistem berbasis LLM dan RAG yang terdiri dari tiga pipeline utama yang diorkestrasikan menggunakan *framework LangGraph* sebagai StateGraph. Setiap *pipeline* diimplementasikan sebagai serangkaian *node* yang dapat dijalankan, diuji, dan diganti secara independen.



Gambar III.1 Pipeline Analisis Kepatuhan

Pipeline pertama (Gambar III.1) adalah analisis kepatuhan, pipeline analisis kepatuhan regulasi yang dijalankan per kontrak. *Pipeline* ini menerima ID kontrak sebagai input, mengambil teks kontrak yang telah diekstrak, mengambil chunk regulasi yang relevan dari database melalui mekanisme retrieval, mengirimkan teks kontrak beserta konteks regulasi kepada LLM untuk dianalisis, kemudian menyimpan temuan analisis kepatuhan ke database sembari mengeluarkan hasil terstruktur.


Sebagai ilustrasi, ketika pipeline ini menganalisis sebuah dokumen Surat Perjanjian pengadaan, sistem mengambil chunk regulasi yang relevan dan membandingkannya dengan klausul kontrak. Salah satu contoh temuan terstruktur yang bisa dihasilkan adalah sebagai berikut:

- Label: *non compliant*
- Kategori: Denda Keterlambatan Pelaksanaan Pekerjaan
- Penjelasan: Regulasi mengharuskan denda keterlambatan sebesar 1/1000 (satu per seribu) dari nilai kontrak untuk setiap hari keterlambatan, sedangkan kontrak hanya menetapkan

sanksi administratif berupa peringatan tertulis tanpa nilai finansial yang dapat dikompensasi.

- Kondisi dokumen terkini: Klausul denda keterlambatan dengan nilai finansial tidak ditemukan dalam kontrak.
- Sitasi: Temuan ditautkan ke regulasi dan chunk regulasi yang menjadi dasar penilaian.

Contoh ini memperlihatkan bagaimana sistem tidak hanya memberikan label kepatuhan, tetapi juga menyertakan penjelasan dan sitasi ke pasal regulasi, sehingga auditor dapat menelusuri kembali dasar hukum dari setiap temuan.



Gambar III.2 Pipeline Analisis Entitas

Pipeline kedua (Gambar III.2) adalah analisis entitas, *pipeline* analisis validitas dan inkonsistensi entitas yang juga dijalankan per kontrak. Berbeda dari analisis kepatuhan, *pipeline* ini dirancang untuk menganalisis bagian yang mungkin terlewat dari sistem *retrieval* karena ketiadaan entitas. Prosesnya dimulai dengan menerima data entitas terstruktur (JSON) hasil ekstraksi modul OCR, merangkumnya menjadi narasi kueri menggunakan LLM, mengambil konteks regulasi berdasarkan narasi tersebut, kemudian menganalisis inkonsistensi data entitas dan kepatuhan terhadap regulasi.

Sebagai contoh, ketika *pipeline* ini memproses data entitas hasil ekstraksi dari sebuah kontrak, sistem menghasilkan temuan yang terbagi ke dalam dua kategori. Pada kategori *entity issues* (masalah kualitas data tanpa dasar regulasi), salah satu temuan adalah sebagai berikut:

- Label: Inkonsisten

- Tipe inkonistensi: nilai moneter
- Penjelasan: Terdapat perbedaan antara nilai angka (Rp 47.765.320,00) dengan nilai terbilang ("Dua Ratus Empat Puluh Tujuh Juta Tujuh Ratus Enam Puluh Lima Ribu Tiga Ratus Dua Puluh Rupiah") yang tidak sesuai.
- Kondisi dokumen terkini: Nilai kontrak tidak sinkron antara penulisan angka dan huruf.

Selain *entity issues*, temuan pada *pipeline* ini juga bisa menghasilkan *entity compliance issues* yang mirip dengan *entity issues* namun selalu menyertakan sitasi ke *chunk* regulasi karena berkaitan dengan pelanggaran ketentuan pengadaan.

Pipeline ketiga adalah *chunker*. Alur ini dijalankan secara offline untuk setiap regulasi baru. *Pipeline* ini menerima input berupa data regulasi yang tersimpan di database beserta file ekstraksi teks dalam format JSON, kemudian memotong teks regulasi menjadi *chunk-chunk* kecil, menghasilkan embedding vektor untuk setiap *chunk*, dan menyimpannya ke dalam PostgreSQL dengan ekstensi pgvector. Pipeline ini mendukung empat strategi *chunking* yang dapat dipilih: *fixed-size*, *semantic*, *late chunking*, dan *parent-child chunking*.

Tabel berikut merangkum pemetaan antara setiap permasalahan yang diidentifikasi pada III.2 dengan solusi teknis yang diterapkan dalam penelitian ini.

Tabel III.2 Gambaran Umum Solusi

ID Masalah	Analisis & Rancangan Solusi
M-01, M-02	Pengembangan Strategi Segmentasi Dokumen (<i>Chunking</i>) yang Adaptif: Merancang dan menguji komparasi metode pemecahan teks (<i>chunking strategy</i>) yang mampu mempertahankan koherensi semantik. Solusi ini bertujuan mencari metode yang paling efektif dalam menjaga keutuhan makna pasal meskipun dokumen harus dipecah untuk diproses oleh model.
M-03	Sistem <i>Retrieval</i> Kontekstual untuk Dokumen Panjang: Mengembangkan mekanisme pencarian yang mampu menangani <i>query</i> kompleks berupa klausul kontrak dan memetakannya ke basis pengetahuan regulasi secara presisi. Solusi ini akan mengeksplorasi teknik pencarian yang dapat menangkap makna semantik sekaligus detail spesifik seperti nomor pasal.
M-01, M-04	Pipeline Generasi dengan Penanganan Konteks Panjang: Membangun <i>pipeline</i> menggunakan <i>Large Language Model</i> yang memiliki kapabilitas <i>long-context</i> untuk modul Analisis Inkonsistensi dan modul RAG bagian <i>generation</i> . Sistem juga perlu dilengkapi dengan mekanisme <i>prompting</i> terstruktur untuk memandu model melakukan penalaran bertahap dan memitigasi halusinasi dengan mewajibkan sitasi sumber.
M-05	Implementasi Kerangka Evaluasi Otomatis: Mengembangkan modul evaluasi keberhasilan sistem yang dapat mengukur kualitas <i>retrieval</i> dan <i>generation</i> secara kuantitatif. Modul ini akan berfungsi sebagai <i>post-hoc evaluation</i> untuk menilai tingkat kepercayaan dari setiap hasil analisis yang dikeluarkan sistem.
Integrasi	Penyelarasan Antarmuka Input-Output Sistem: Merancang skema pertukaran data yang terstandarisasi untuk memastikan subsistem ini dapat menerima input data dari modul OCR dan dapat menyajikan hasil analisis ke modul <i>Agentic AI</i> pada sistem <i>capstone</i> secara keseluruhan.

III.3.1 Penggunaan Kakas pada Sistem

Pemilihan kakas dalam penelitian ini didasarkan pada kebutuhan masing-masing *pipeline*, ketersediaan secara *open-source*, serta kompatibilitas dengan lingkungan eksperimen yang digunakan. *Pipeline knowledge base* membutuhkan kakas yang mampu menangani penyimpanan vektor embedding, sedangkan *pipeline analisis* membutuhkan LLM berkapasitas besar yang dapat dijalankan secara lokal maupun lewat API. *Pipeline retrieval* membutuhkan implementasi pencarian berbasis vektor dan berbasis kata kunci yang dapat dikombinasikan.

Tabel III.3 Kakas

Kakas	Modul	Peran dalam Pipeline
LangGraph	Semua pipeline	Berfungsi sebagai <i>framework</i> orkestrasi workflow. Setiap langkah dalam pipeline diimplementasi sebagai <i>node-node</i> yang terhubung, mempermudah konfigurasi dan pengujian untuk setiap <i>node</i> -nya.
PostgreSQL + pgvector	Semua pipeline	Basis data utama untuk menyimpan metadata regulasi, kontrak, chunk teks, dan embedding vektor.
SQLAlchemy + Alembic	Semua pipeline	SQLAlchemy digunakan sebagai ORM untuk mengakses dan memanipulasi data. Alembic digunakan untuk manajemen migrasi skema database.
BGE-M3	Semua pipeline	Model embedding multibahasa bge-m3 yang dijalankan secara lokal menggunakan <i>library</i> SentenceTransformers.

Kakas	Modul	Peran dalam Pipeline
Google Gemini	Pipeline analisis	Berfungsi sebagai LLM pengevaluasi dalam kerangka RAGAS
Ollama	Pipeline analisis	Berfungsi sebagai antarmuka LLM lokal
Python	Semua	Bahasa pemrograman utama untuk seluruh implementasi sistem.

III.3.2 Data


Data yang digunakan dalam penelitian ini terdiri dari dua komponen utama: basis pengetahuan regulasi dan dataset kontrak publik untuk eksperimen analisis.

Basis pengetahuan regulasi bersumber dari dokumen peraturan yang dipublikasikan di situs JDIH LKPP (Jaringan Dokumentasi dan Informasi Hukum Lembaga Kebijakan Pengadaan Barang/Jasa Pemerintah). Peraturan yang digunakan mencakup regulasi terkait pengadaan barang dan jasa pemerintah, mencakup sebagian peraturan presiden dan sebagian peraturan LKPP yang dibatasi pada lima peraturan yakni:

1. Peraturan Presiden (Perpres) Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
2. Peraturan Presiden (Perpres) Nomor 46 Tahun 2025 tentang Perubahan Kedua atas Peraturan Presiden Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
3. Peraturan Presiden (Perpres) Nomor 12 Tahun 2021 tentang Perubahan atas Peraturan Presiden Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
4. Peraturan Lembaga Kebijakan Pengadaan Barang/Jasa Pemerintah Nomor 4 Tahun 2024 tentang Perubahan Atas Peraturan Lembaga Kebijakan Pengadaan Barang/Jasa
5. Pemerintah Nomor 12 Tahun 2021 tentang Pedoman Pelaksanaan Pengadaan Barang/Jasa Pemerintah Melalui Penyedia

Setiap dokumen regulasi disimpan dalam *database* untuk *metadata*-nya dan tersimpan juga dalam bentuk JSON untuk bagian ekstraksi teks dan ekstraksi entitas yang telah disiapkan dari modul lain dalam capstone ini yakni modul OCR.

Data regulasi nantinya akan dipecah menjadi potongan-potongan teks untuk digunakan dalam sistem RAG. Skema database yang mendukung komponen data regulasi ini ditampilkan pada gambar III.3.




Gambar III.3. Skema Basis Data Regulasi

Dataset kontrak publik terdiri dari dokumen Surat Perintah Kerja (SPK) yang diperoleh dari berbagai sumber publik. *Metadata* dan hubungan antara kontrak dan dokumen kontrak disimpan

dalam database. Isi dokumen kontrak, yang berbentuk ekstraksi teks mentah dan ekstraksi entitas, disimpan secara terpisah dalam format JSON.

Skema *database* yang mendukung komponen data regulasi ini ditampilkan pada gambar III.4.



Gambar III.4. Skema Basis Data Kontrak Publik

III.3.3 Implementasi Pipeline Chunking

Pipeline ini bertanggung jawab untuk memproses data teks berformat JSON hasil ekstraksi dari dokumen peraturan menjadi potongan teks beserta representasi vektor yang dapat dicocokkan. Pengembangan modul ini secara garis besar memiliki dua tahap utama:

1. Segmentasi Teks:

Teks peraturan yang panjang akan dipecah menjadi segmen-segmen (*chunks*) yang lebih kecil dengan batasan tertentu.

2. Pembentukan Vektor:

Setiap *chunk* teks yang terbentuk kemudian akan dikonversi menjadi representasi vektor numerik. Model *embedding* yang digunakan adalah BGE-M3, yang dipilih karena kapabilitas *multilinguality* dan *multigranularity*-nya.

Hasil dari kedua tahap diatas kemudian akan disimpan ke database dengan ekstensi yang dapat menyimpan representasi vektor numerik.

Pada implementasinya, modul ini akan dikembangkan menjadi hasil dari serangkaian proses yang dijelaskan pada tabel berikut.

Tabel III.4 Proses Chunking

Nama Proses	Penjelasan
Load regulation	Mengambil entitas regulasi dari database berdasarkan <i>regulation_id</i> yang diberikan. Memvalidasi bahwa regulasi memiliki apakah ada teks hasil ekstraksi yang valid
Load extracted document	Membaca file JSON ekstraksi teks dari jalur yang tersimpan di database.
Chunk regulation	Memotong regulasi yang panjang menjadi potongan-potongan teks
Embed chunks	Membuat <i>embedding vector</i> untuk setiap potongan teks sesuai dengan metode chunk yang dipilih
Persist chunks	Menghapus chunk lama dari database untuk regulasi yang sama (penghapusan dilakukan untuk memberi opsi untuk merubah ukuran <i>chunk</i>), menyimpan chunk dan embedding baru, dan menandai regulasi sebagai sudah di-chunk.

Modul Chunking yang diimplementasikan mendukung tiga strategi yang dapat dipilih melalui penggunaan *flag* “--chunking-mode” saat pemanggilan. Ketiga strategi itu adalah *fixed-size chunking*, *late chunking*, dan *semantic chunking*.

Fixed-size chunking memotong teks berdasarkan jumlah karakter tetap dengan *overlap*.

Late chunking memproses seluruh dokumen terlebih dahulu melalui BGE-M3 untuk memperoleh representasi pada level token, kemudian token-token dalam setiap span chunk di-pooling (*mean pooling*) menjadi satu vektor per chunk.

Semantic chunking menempatkan batas chunk pada posisi terjadinya perpindahan makna. Pada implementasinya, teks terlebih dahulu dipecah menjadi segmen-segmen dasar berdasarkan tanda baca akhir kalimat dan baris baru. Setiap segmen kemudian di-embedding, lalu jarak (*cosine distance*) antar segmen bertetangga dihitung. Batas chunk ditempatkan pada posisi di mana jarak tersebut melampaui ambang batas persentil tertentu (*breakpoint percentile*).

Ketiga strategi ini disimpan pada tabel chunk yang terpisah sehingga setiap regulasi dapat diindeks dalam lebih dari satu mode dan dibandingkan secara langsung pada tahap eksperimen.

III.3.4 Implementasi Tahap Retrieval

Pada *pipeline* analisis kepatuhan dan analisis entitas, dibutuhkan pengambilan konteks dari data regulasi. *Pipeline* yang menggunakan tahap ini akan mengirimkan kueri yang mereka inginkan. Kueri tersebut akan diubah menjadi vektor embedding untuk dicocokkan dengan *chunk-chunk* regulasi yang ada.

Sistem yang diimplementasikan mendukung tiga mode retrieval yang dapat dipilih melalui parameter yakni *dense retrieval*, *sparse retrieval*, dan *Hybrid Retrieval*. Selain itu sistem ini juga dilengkapi dengan opsi untuk melakukan *reranking* yang akan dilakukan dengan BGE-reranker-v2-M3 yang cocok digunakan bersama *embedding* BGE-M3.

III.3.5 Implementasi Pipeline Analisis Kepatuhan

Pipeline analisis kepatuhan merupakan salah satu inti dari sistem yang bertugas melakukan deteksi analisis kepatuhan kontrak. Pengembangan pipeline ini diorkestrasikan menggunakan Langgraph untuk mengatur alur kerjanya. Modul ini secara garis besar memiliki dua tahap utama:

1. *Retrieval*

Tahapan ini akan mengubah *query*, yang pada sistem ini merupakan teks dari dokumen kontrak menjadi *embedding vector*. Hal ini kemudian akan digunakan untuk mengambil *chunk-chunk* peraturan yang cocok.

2. *Generation*

Potongan-potongan teks peraturan yang telah diambil sebelumnya akan dimasukkan ke *prompt* bersamaan dengan dokumen kontrak yang akan dianalisis.

Dari dua tahap tersebut, modul dikembangkan menjadi beberapa proses yang lebih rinci dalam implementasinya.

Tabel III.5 Proses Analisis Kepatuhan

Nama Proses	Penjelasan
Load contract	Mengambil kontrak yang akan dianalisis
Load contract documents	Mengambil kumpulan dokumen dari kontrak
Assemble contract text	Menggabungkan teks dari dokumen-dokumen kontrak yang digunakan
Retrieve regulation context	Mengambil potongan-potongan peraturan yang berhubungan dengan dokumen-dokumen kontrak yang akan dianalisis
Analyze compliance/inconsistency	Menganalisis kepatuhan atau inkonsistensi berdasarkan dokumen dan peraturan yang didapat
Persist findings	Menyimpan hasil analisis ke dalam basis data

Keluaran dari *pipeline* ini berupa objek yang merangkum seluruh hasil analisis dalam satu bentuk terstruktur. Objek ini memuat beberapa objek *findings* yang memuat atribut-atribut berikut:

1. *Label*: Status kepatuhan untuk aspek terkait (compliant, non_compliant, atau needs_review).
2. *Category*: Kategori pelanggaran (misalnya "Denda Keterlambatan", "Jaminan Pelaksanaan").
3. *Explanation*: Penjelasan konkret mengenai apa yang dilanggar, pasal yang menjadi acuan, dan implikasinya menyediakan elemen explainability bagi auditor.
4. *Current document state*: Deskripsi kondisi aktual klausul dalam kontrak, atau keterangan "Tidak ditemukan dalam kontrak" bila klausul tersebut tidak ada.
5. *Document excerpt*: Kutipan verbatim teks kontrak yang menjadi dasar temuan.
6. *Citations*: Daftar sitasi yang menghubungkan temuan ke chunk regulasi spesifik beserta regulation_id, regulation_chunk_id, dan kutipan teksnya. Sitasi ini memitigasi risiko

halusinasi karena setiap temuan dapat ditelusuri kembali ke chunk regulasi yang nyata ada di database.

III.3.6 Implementasi Pipeline Analisis Entitas

Pipeline analisis entitas merupakan inti sistem lainnya yang akan melakukan inkonsistensi dan validasi entitas. Pipeline ini diimplementasikan melalui enam *node* berurutan yang detailnya ditampilkan pada tabel III.6.

Tabel III.6 Proses Analisis Entitas

Nama Proses	Penjelasan
Load contract	Mengambil kontrak yang sesuai dari database
Load entity documents	Mengambil satu atau lebih dokumen hasil ekstraksi entitas dari kontrak yang sesuai
Summarize entities	Menggunakan LLM untuk meringkas kumpulan dokumen hasil ekstraksi menjadi sebuah narasi ringkasan entitas dalam Bahasa Indonesia.
Retrieve regulation context	Menggunakan narasi ringkasan entitas sebagai kueri untuk mengambil <i>chunk</i> regulasi yang relevan
Analyze entities	Menggunakan LLM menganalisis inkonsistensi dan kepatuhan terkait entitas berdasarkan konteks yang sudah didapatkan
Persist findings	Menyimpan temuan inkonsistensi entitas baru bersama sitasinya

Keluaran akhir pipeline ini berupa objek dengan struktur berupa kumpulan *findings* yang dipisahkan menjadi dua sesuai dengan bagaimana validitas entitas dianalisis. Pemisahan dua kategori temuan ini mencerminkan dua sifat audit yang berbeda: audit kualitas data internal dan audit kepatuhan terhadap regulasi.

Yang pertama adalah *entity issues*, temuan ini memuat masalah kualitas data entitas yang dapat dideteksi tanpa dasar regulasi. Setiap temuan dalam kategori ini, apabila berlabel inconsistent, wajib diklasifikasikan ke dalam salah satu dari empat jenis inkonsistensi:

1. nilai_moneter (Inkonsistensi nilai moneter): ketidakcocokan antara nominal angka dan terbilang, misalnya "Rp 150.000.000" dengan terbilang yang tidak sesuai.

2. identitas (Inkonsistensi identitas): artefak OCR pada nama/jabatan yang tampak rusak secara semantik, atau nama/jabatan yang berbeda untuk entitas yang sama di bagian pihak pertama, pihak kedua, dan penandatanganan.
3. temporal (Inkonsistensi temporal): ketidakkonsistenan tanggal antar field, misalnya tanggal mulai lebih awal dari tanggal kontrak atau tanggal berakhir lebih awal dari tanggal mulai.
4. lain (Inkonsistensi lain): masalah kualitas data yang tidak masuk tiga kategori di atas, misalnya field wajib yang bernilai null atau kosong.

Yang kedua adalah *entity compliance issues* yang memuat pelanggaran regulasi berbasis data entitas. Berbeda dari *entity issues*, setiap temuan wajib memiliki sitasi ke *chunk* regulasi. Contoh: temuan mencakup nilai kontrak yang melampaui batas pengadaan langsung tanpa tender, jenis jaminan yang tidak sesuai ketentuan, atau format dokumen yang tidak memenuhi syarat administratif regulasi.

Kedua kategori menggunakan struktur temuan yang sama dengan *pipeline* analisis kepatuhan, namun nilai label pada *entity issues* menggunakan *consistent*, *inconsistent*, atau *needs review*, sementara *entity compliance issues* menggunakan *compliant*, *non compliant*, atau *needs review* mengikuti konvensi audit regulasi.

III.3.7 Keterbatasan Penanganan Perubahan Regulasi

Salah satu karakteristik fundamental dari domain regulasi pengadaan adalah sifatnya yang dinamis: sebuah peraturan kerap diubah oleh peraturan yang lebih baru melalui mekanisme perubahan. Pada perancangan basis data, sistem ini telah menyediakan tabel *regulation_relation* yang dapat merekam hubungan antara regulasi, termasuk hubungan perubahan (misalnya bahwa Perpres Nomor 46 Tahun 2025 merupakan perubahan atas Perpres Nomor 16 Tahun 2018). Namun, perlu ditegaskan bahwa pada penelitian ini relasi tersebut belum dimanfaatkan untuk melakukan rekonsiliasi otomatis atas perubahan regulasi. Dengan kata lain, sistem menyimpan informasi *bahwa* sebuah regulasi mengubah regulasi lain, tetapi belum mampu menerapkan makna perubahan tersebut untuk menghasilkan satu versi regulasi yang terkonsolidasi dan termutakhir.

Ketidakmampuan ini bukan semata-mata persoalan implementasi, melainkan berakar pada kompleksitas struktural cara perubahan regulasi dituliskan. Penerapan perubahan secara otomatis menuntut sistem untuk dapat memisahkan dan mengidentifikasi setiap ayat di dalam setiap pasal secara presisi, agar perubahan dapat ditujukan ke unit hukum yang tepat. Pada praktiknya, hal ini sulit dilakukan karena dua alasan utama berikut.

Pertama, perubahan regulasi sering kali dituliskan dalam bentuk penulisan ulang sebuah pasal secara utuh di dalam tubuh peraturan pengubah. Akibatnya, penomoran ayat yang muncul di dalam teks perubahan menjadi ambigu: tidak ada pembeda yang signifikan antara ayat yang merupakan struktur asli peraturan pengubah dengan ayat yang sebenarnya merupakan bagian dari pasal yang sedang ditulis ulang. Sebagai contoh, pada Peraturan Presiden Nomor 46 Tahun 2025 sebagaimana ditampilkan pada Gambar III.5, sebuah ketentuan menyatakan bahwa ayat pada Pasal 19 diubah dan disisipkan satu ayat baru (ayat 1a), sehingga "Pasal 19 berbunyi sebagai berikut" diikuti oleh penulisan ulang ayat (1), (1a), dan (2) secara lengkap. Penomoran ayat (1), (1a), dan (2) di sini berada di dalam konteks pasal yang ditulis ulang, bukan struktur ayat tingkat atas dari dokumen peraturan pengubah itu sendiri. Hal ini juga berlaku dengan penulisan "Pasal 19" pada gambar tersebut. Tanpa pemahaman semantik terhadap kalimat pembingkai ("sehingga Pasal 19 berbunyi sebagai berikut") dan batas belakang dari perubahan tersebut, sistem tidak dapat membedakan keduanya secara andal.

10. Ketentuan ayat (1) dan ayat (2) Pasal 19 diubah, dan di antara ayat (1) dan ayat (2) disisipkan 1 (satu) ayat yakni ayat (1a), sehingga Pasal 19 berbunyi sebagai berikut:

Pasal 19

- (1) PPK dalam menyusun spesifikasi teknis/kerangka acuan kerja Barang/jasa menggunakan:
 - a. Produk Dalam Negeri;
 - b. Produk bersertifikat Standar Nasional Indonesia;
 - c. Produk Usaha Mikro dan Usaha Kecil serta koperasi dari hasil produksi dalam negeri; dan
 - d. Produk Ramah Lingkungan Hidup.
- (1a) PPK dalam menyusun spesifikasi teknis/kerangka acuan kerja Barang/jasa menggunakan Produk Dalam Negeri sebagaimana dimaksud pada ayat (1) huruf a menyesuaikan dengan kemampuan industri dalam negeri sebagaimana tercantum dalam daftar inventarisasi Barang/jasa produksi dalam negeri yang diterbitkan oleh kementerian yang menyelenggarakan urusan pemerintahan di bidang perindustrian.
- (2) Dalam penyusunan spesifikasi teknis/kerangka acuan kerja dimungkinkan penyebutan merek terhadap:
 - a. komponen Barang/jasa;
 - b. suku cadang;
 - c. bagian dari satu sistem yang sudah ada; atau
 - d. Barang/jasa dalam katalog elektronik.
- (3) Pemenuhan . . .

Gambar III.5. Potongan Penulisan Perubahan Peraturan
(Sumber: Peraturan Presiden Nomor 46 Tahun 2025)

Kedua, tidak semua ketentuan regulasi dituliskan secara tepat dalam unit pasal atau ayat yang bersih. Sebagian ketentuan, terutama yang termuat dalam lampiran atau pedoman pelaksanaan, ditulis dalam struktur penomoran tersendiri yang tidak mengikuti pola pasal-ayat. Sebagai contoh, ketentuan mengenai Uang Muka pada Peraturan Lembaga Nomor 4 Tahun 2024 sebagaimana ditampilkan pada Gambar III.6 dimuat di bawah sub-bagian bernomor (2.3.2.4) dalam format pedoman, bukan dalam pasal dan ayat. Struktur semacam ini membuat asumsi "setiap ketentuan dapat dipetakan ke satu pasal dan ayat" menjadi tidak berlaku secara universal, sehingga mekanisme rekonsiliasi berbasis pasal-ayat tidak dapat diterapkan secara menyeluruh.

2.3.2.4 Uang Muka

Uang muka merupakan pembayaran yang dilakukan sebelum pembayaran bulanan atau termin pekerjaan.

PPK dapat memberikan uang muka kepada Penyedia.

PPK menetapkan besaran persentase uang muka yang akan diberikan kepada Penyedia dan dicantumkan pada rancangan Kontrak yang terdapat dalam Dokumen Pemilihan.

Besaran persentase uang muka diberikan sebagai berikut:

- a. paling tinggi 20% (dua puluh persen) dari nilai Kontrak; atau
- b. paling tinggi 15% (lima belas persen) dari nilai Kontrak untuk Kontrak tahun jamak.

Besaran uang muka ditentukan dalam Data Kontrak.

Gambar III.6. Potongan Penulisan Peraturan dengan Struktur Unik

(Sumber: Peraturan Lembaga Nomor 4 Tahun 2024)

Sebagai konsekuensi dari kedua tantangan tersebut, penelitian ini mengambil keputusan desain untuk memasukkan seluruh regulasi terkait (baik peraturan asli maupun peraturan pengubahnya) ke dalam basis pengetahuan secara berdampingan, tanpa melakukan konsolidasi versi. Implikasinya, tahap *retrieval* berpotensi mengambil chunk dari pasal yang sebenarnya telah diubah atau dicabut. Penanganan perubahan regulasi secara otomatis, yang memerlukan *parsing* struktural tingkat ayat beserta pemahaman semantik atas kalimat perubahan, diposisikan sebagai arah pengembangan lanjutan, sebagaimana akan dibahas pada Bab V.

III.3.8 Pengujian Sistem

Pengujian sistem dirancang untuk mengisolasi dan mengukur kinerja dari masing-masing komponen RAG. Pendekatan pengujian akan dilakukan dengan menggunakan metode eksperimen terkontrol, di mana ketika satu komponen sedang diuji, komponen lainnya akan ditetapkan pada konfigurasi konstan.

Kerangka kerja utama yang digunakan untuk pengujian adalah RAGAS (*Retrieval Augmented Generation Assessment*). RAGAS memungkinkan evaluasi yang bersifat *reference-free* dengan mekanisme LLM-as-a-Judge, memungkinkan pengujian skenario kontrak yang terotomasi terlepas dari keperluan anotasi manual oleh pakar hukum. Pengujian akan menyimulasikan berbagai kueri kasus kontrak publik untuk melihat seberapa baik sistem dapat mendapat regulasi yang sesuai dan menarik kesimpulan dengan analisis yang sesuai.

III.3.9 Evaluasi Hasil

Hasil dari pengujian sistem akan dievaluasi secara kuantitatif dengan membaginya ke dalam dua aspek utama sesuai arsitektur RAG:

1. Evaluasi Modul Retrieval: Mengukur seberapa akurat sistem menemukan *chunk* regulasi yang relevan dari basis data. Metrik yang digunakan adalah *Context Relevance* yang diambil dari RAGAS untuk menghitung rasio informasi relevan yang diambil.
2. Evaluasi Modul Generasi: Mengukur kualitas analisis yang dihasilkan oleh LLM. Metrik yang digunakan bertumpu pada RAGAS yaitu *Faithfulness*, metrik yang memastikan analisis sepenuhnya didasarkan pada konteks, dan *Answer Relevance*, metrik yang memastikan analisis menjawab sesuai dengan klausul yang sedang dibahas/ditanyakan.

III.4 Rancangan Eksperimen

Untuk menjawab rumusan masalah mengenai pembangunan sistem deteksi inkonsistensi dan analisis kepatuhan yang akurat, penelitian ini mengusulkan pendekatan eksperimental dalam beberapa bagian. Eksperimen dirancang untuk menguji berbagai macam pendekatan ataupun teknologi yang merupakan *state-of-the-art* sehingga didapatkan cara yang paling tepat berdasarkan metode pengukuran performa yang ditentukan.

III.4.1 Eksperimen Strategi Chunking

Untuk mengatasi masalah fragmentasi konteks (M-02), eksperimen akan membandingkan performa beberapa strategi pemecahan teks dokumen regulasi LKPP:

1. *Baseline*: Pemotongan standar, *fixed-size chunking* dengan *overlap*.
2. *Advanced Chunking*: Membandingkan *late chunking* dan *semantic chunking*.

III.4.2 Eksperimen Strategi Retrieval

Mengingat query dari kontrak dokumen yang panjang (M-03), perlu eksperimentasi dan diuji untuk menemukan cara yang paling efektif. Pendekatan yang akan dicoba adalah Sparse retrieval, Dense Retrieval, dan Hybrid Retrieval.

III.4.3 Eksperimen Ukuran LLM

Tahap ini bertujuan menentukan konfigurasi LLM yang paling optimal untuk tugas analisis kepatuhan kontrak publik (M-04). Eksperimen akan membandingkan pengaruh ukuran model dan keluarga model terhadap kualitas analisis yang dihasilkan. Model yang dibandingkan mencakup dua varian Qwen3 yang dijalankan secara lokal melalui Ollama dengan ukuran parameter yang bervariasi, serta model Gemini sebagai referensi model berukuran besar berbasis API. Seluruh eksperimen menggunakan strategi prompt yang sama (*zero-shot*) dan konfigurasi *retrieval* yang sama sehingga perbedaan hasil dapat diatribusikan sepenuhnya pada kapabilitas model. Parameter temperatur ditetapkan pada nilai 0.0 untuk seluruh model guna memastikan output yang deterministik dan dapat direproduksi. Evaluasi menggunakan metrik *faithfulness* dan *answer relevance* dari kerangka RAGAS untuk mengukur kualitas analisis yang dihasilkan, serta waktu inferensi sebagai pertimbangan efisiensi praktis.

III.4.4 Eksperimen Reranking

Eksperimen ini bertujuan menguji apakah penambahan tahap *reranking* dengan *cross-encoder* dapat meningkatkan relevansi konteks yang diambil. *Reranker* yang digunakan adalah BGE-reranker-v2-M3 yang kompatibel dengan *embedding* BGE-M3. Pengujian membandingkan konfigurasi tanpa *reranking* dengan konfigurasi yang melakukan *over-fetch* sejumlah kandidat awal kemudian menyortir ulang menjadi *top_k* akhir. Metrik yang diukur adalah context relevance dan latensi tahap retrieval.

III.4.5 Eksperimen Strategi Instruksi (Prompt)

Eksperimen ini bertujuan menentukan strategi instruksi yang paling efektif untuk memandu LLM. Tiga strategi dibandingkan: *zero-shot* (instruksi saja), *role-prompt* (instruksi disertai pemberian peran auditor), dan *few-shot* (instruksi disertai contoh input-output). Model dikontrol pada Gemini-3.5-flash-lite sebagai model yang terbukti paling konsisten menghasilkan format keluaran valid. Metrik yang diukur adalah *faithfulness*, *response relevancy*, dan *format validity*.

BAB IV EKSPERIMEN DAN EVALUASI

Bab ini memaparkan konfigurasi lingkungan eksperimen, deskripsi dataset yang digunakan, serta penjabaran skenario eksperimen beserta hasil evaluasinya. Fokus utama dari bab ini adalah memvariasikan berbagai metode untuk mengukur efektivitas strategi *retrieval* dan strategi generasi terkait dalam melakukan deteksi inkonsistensi dan analisis kepatuhan pada dokumen kontrak publik.

IV.1 Lingkungan Eksperimen

Eksperimen dalam penelitian ini dilakukan dengan menggunakan perangkat keras dan perangkat lunak untuk mendukung berjalannya subsistem. Rincian spesifikasi lingkungan eksperimen yang digunakan dijabarkan pada tabel IV.1 berikut.

Tabel IV.1. Spesifikasi Lingkungan Eksperimen

Komponen	Spesifikasi
Prosesor	AMD Ryzen 7 260 (8 core / 16 thread)
GPU	NVIDIA GeForce RTX 5050 Laptop (8 GB VRAM)
RAM	32 GB DDR5-7500
Sistem Operasi	Windows 11 Home Single Language (64-bit)
Bahasa Pemrograman	Python 3.14.3
CUDA	CUDA 13.2 (Driver 595.97)
LLM Lokal	Ollama (qwen3.5:2b, qwen3.5:4b)
LLM API	Google Gemini 3.1 Flash Lite
LLM Judge (RAGAS)	DeepInfra openai/gpt-oss-120b
<i>Framework</i> Evaluasi	RAGAS

Model *embedding* BGE-M3 dijalankan secara lokal menggunakan akselerasi CUDA pada GPU yang tersedia. Seluruh eksperimen menggunakan $\text{top}_k=10$, untuk pengambilan *chunk*. Skenario eksperimen yang dijalankan dirangkum pada tabel berikut.

Tabel IV.2. Skenario Eksperimen

No	Eksperimen	Variabel yang Divariasi	Variabel yang Dikontrol	Metrik Evaluasi
1	Strategi <i>Chunking</i>	Metode chunking: <i>fixed</i> , <i>late</i> , <i>semantic</i>	<i>Retrieval: hybrid</i> top_k=10 tanpa <i>reranking</i>	<i>Context Relevance</i>
2	Strategi <i>Retrieval</i>	Mode retrieval (dense, sparse, hybrid 50/50, 70/30, 30/70)	<i>Chunk: fixed</i> top_k=10 tanpa <i>reranking</i>	<i>Context Relevance</i>
3	Ukuran LLM	Model analisis (Gemini, Qwen 2B, Qwen 4B)	<i>Retrieval: dense</i> <i>chunk: fixed</i> <i>prompt: zero-shot</i>	<i>Faithfulness</i> , <i>Response</i> <i>Relevancy</i> , <i>Format</i> <i>Validity</i> , <i>Latensi</i>
4	Strategi <i>Prompting</i>	<i>Prompting technique: zero-shot, role-prompt, few-shot</i>	Model: Gemini <i>retrieval: dense</i> <i>chunk: fixed</i>	<i>Faithfulness</i> , <i>Response</i> <i>Relevancy</i> , <i>Format Validity</i>

IV.2 Dataset

Dataset yang digunakan dalam eksperimen ini terdiri dari dua komponen utama, yaitu dataset regulasi yang berfungsi sebagai basis pengetahuan dan dataset dokumen kontrak publik yang berfungsi sebagai data uji.

IV.2.1 Dataset Regulasi

Dataset regulasi merupakan kumpulan dokumen peraturan perundang-undangan yang mengatur pengadaan barang dan jasa pemerintah di Indonesia yang diekstraksi ke bentuk teks mentah. Dokumen ini diperoleh dari situs Jaringan Dokumentasi dan Informasi Hukum Lembaga Kebijakan Pengadaan Barang/Jasa Pemerintah (JDIH LKPP).

Sesuai dengan batasan masalah, peraturan yang dimasukkan ke dalam basis data vektor meliputi:

1. Peraturan Presiden (Perpres) Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah

2. Peraturan Presiden (Perpres) Nomor 46 Tahun 2025 tentang Perubahan Kedua atas Peraturan Presiden Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
3. Peraturan Presiden (Perpres) Nomor 12 Tahun 2021 tentang Perubahan atas Peraturan Presiden Nomor 16 Tahun 2018 tentang Pengadaan Barang/Jasa Pemerintah
4. Peraturan Lembaga Kebijakan Pengadaan Barang/Jasa Pemerintah Nomor 4 Tahun 2024 tentang Perubahan Atas Peraturan Lembaga Kebijakan Pengadaan Barang/Jasa Pemerintah Nomor 12 Tahun 2021 tentang Pedoman Pelaksanaan Pengadaan Barang/Jasa Pemerintah Melalui Penyedia

Basis data vektor yang dihasilkan dari strategi *fixed-size chunking* dan *late chunking* masing-masing memuat 3.166 *embedded chunk*, sedangkan strategi *semantic chunking* menghasilkan 3.673 *chunk* karena adanya variasi ukuran.

IV.2.2 Dataset Kontrak Publik

Dataset dokumen kontrak publik digunakan sebagai data uji untuk mengevaluasi kemampuan sistem dalam mendeteksi inkonsistensi dan kepatuhan. Dataset ini terdiri dari 30 dokumen Surat Perintah Kerja (SPK) dan Surat Perjanjian yang diperoleh dari berbagai instansi pemerintah di Indonesia, termasuk situs PPID Diskominfo Provinsi Jawa Tengah dan beberapa arsip publik lainnya.

Karakteristik dataset kontrak publik ini adalah sebagai berikut:

- Panjang dokumen: bervariasi dari 4 sampai 19 halaman
- Panjang teks dokumen: bervariasi cukup luas, dari sekitar 2.000 karakter hingga 44.000 karakter

Sistem analisis kepatuhan tidak menerima masukan dalam bentuk PDF mentah, melainkan input berupa ekstraksi teks mentah dan ekstraksi entitas terstruktur yang didapatkan dari modul OCR.

IV.3 Eksperimen Strategi Chunking

Eksperimen ini bertujuan mengidentifikasi metode pemecahan teks regulasi yang paling efektif dalam mempertahankan koherensi semantik sehingga chunk yang diambil benar-benar relevan

dengan kontrak yang dianalisis. Pipeline lainnya dikontrol secara ketat: *retrieval* menggunakan mode *hybrid* dengan bobot seimbang (50/50) dan *top_k*=10 tanpa *reranking*.

IV.3.1 Konfigurasi Eksperimen

Tiga strategi chunking yang dibandingkan adalah sebagai berikut.

Tabel IV.3. Konfigurasi Strategi Chunking

Strategi	Deskripsi
<i>Fixed-size</i>	Pemotongan berdasarkan jumlah karakter tetap dengan <i>overlap</i> menggunakan batas kalimat/paragraf terdekat
<i>Late chunking</i>	Seluruh dokumen diproses terlebih dahulu oleh BGE-M3 untuk mendapatkan representasi token-level, kemudian token-token dalam setiap <i>span chunk</i> di- <i>pooling</i> (menggunakan <i>mean pooling</i>) menjadi satu vektor untuk setiap <i>chunk</i> .
<i>Semantic</i>	Dokumen dipecah berdasarkan deteksi perpindahan topik: kalimat-kalimat di- <i>embedding</i> , kemudian batas <i>chunk</i> ditempatkan di posisi di mana <i>cosine distance</i> antar kalimat bertetangga melampaui ambang batas.

Variabel yang dikontrol adalah *retrieval mode* = *hybrid* 50/50, *top_k* = 10, dan dijalankan tanpa *reranking*. Evaluasi menggunakan metrik *context relevance* dari kerangka RAGAS yang mengukur rasio kalimat relevan dari keseluruhan konteks yang diambil.

IV.3.2 Hasil Evaluasi

Hasil eksperimen strategi chunking pada kedua jenis pipeline analisis disajikan pada tabel berikut.

Tabel IV.4 Hasil Evaluasi Strategi Chunking (Mean Context Relevance)

Strategi Chunking	Analisis Kepatuhan	Analisis Entitas
Fixed-size	0,33	0,06
Late chunking	0,10	0,01
Semantic	0,32	0,09

IV.3.3 Analisis

Pada pipeline analisis kepatuhan, *fixed-size chunking* dan *semantic chunking* menghasilkan *context relevance* yang hampir setara (0,33 dan 0,32), sementara *late chunking* jauh tertinggal di angka 0,10. Pola yang sama terlihat pada pipeline analisis entitas: *semantic chunking* memberikan nilai tertinggi (0,09), diikuti *fixed-size* (0,06), dan kembali *late chunking* paling rendah (0,01).

Kegagalan *late chunking* pada kedua pipeline sejalan dengan temuan Merola dan Singh (2025) bahwa efektivitas metode ini sangat bergantung pada kemampuan model *embedding*. Pada eksperimen ini terlihat bahwa BGE-M3 belum optimal untuk skema *late chunking* pada dokumen regulasi pengadaan, sehingga *vektor chunk* yang dihasilkan justru kehilangan ketepatan dibandingkan pendekatan yang meng-*embed* tiap *chunk* secara langsung. Lebih detailnya hal ini dapat terjadi dikarenakan mekanisme *late chunking* melakukan *mean-pooling* sedangkan model BGE-M3 merupakan model yang dilatih berdasarkan nilai CLS.

Secara keseluruhan, nilai *context relevance* pada pipeline entitas jauh lebih rendah dibandingkan pipeline kepatuhan untuk semua strategi *chunking*. Hal ini mengindikasikan bahwa kesulitan utama *pipeline* entitas bukan terletak pada strategi *chunking* teks, melainkan pada karakteristik *query* ringkasan naratif yang akan dibahas lebih lanjut pada eksperimen *retrieval* dan *reranking*.

IV.4 Eksperimen Strategi Retrieval

Eksperimen ini bertujuan mengidentifikasi strategi pengambilan *chunk* regulasi yang paling efektif mengingat *query* yang digunakan adalah klausul kontrak panjang yang harus dicocokkan dengan basis data regulasi yang besar. Lima konfigurasi retrieval dibandingkan: dense retrieval, sparse retrieval (BM25), dan tiga varian hybrid search yang menggabungkan keduanya dengan bobot berbeda melalui algoritma *Reciprocal Rank Fusion* (RRF).

IV.4.1 Konfigurasi Eksperimen

Variabel yang dikontrol adalah:

- *chunk type* = *fixed*
- *top_k* = 10
- tanpa *reranking*
- Model Analisis = Gemini 3.1 Flash Lite

Lima konfigurasi retrieval yang diuji adalah sebagai berikut.

Tabel IV.5 Konfigurasi Strategi Retrieval

Konfigurasi	Deskripsi
dense	Pencarian berdasarkan kemiripan <i>embedding</i> (<i>cosine similarity</i>)
sparse	Pencarian kata kunci BM25
hybrid 50/50	<i>Hybrid RRF</i> dengan bobot <i>dense:sparse</i> = 50:50
hybrid 70/30	<i>Hybrid RRF</i> dengan bobot <i>dense:sparse</i> = 70:30
hybrid 30/70	<i>Hybrid RRF</i> dengan bobot <i>dense:sparse</i> = 30:70

Sama seperti pengujian sebelumnya, nilai yang diukur adalah *context relevance* yang dinilai oleh model gpt-oss-120b.

IV.4.2 Hasil Evaluasi

Berdasarkan hasil pengujian, berikut rata-rata nilai *context relevance* yang didapat.

Tabel IV.6 Hasil Evaluasi Strategi Retrieval (Mean Context Relevance)

Konfigurasi Retrieval	Analisis Kepatuhan	Analisis Entitas
dense	0,27	0,04
sparse	0,16	0,08
hybrid 50/50	0,32	0,15
hybrid 70/30	0,34	0,10
hybrid 30/70	0,27	0,14

IV.4.3 Analisis

Pada pipeline analisis kepatuhan, seluruh konfigurasi *hybrid* mengungguli atau menyamai *dense* murni, dan *sparse* murni menjadi yang paling rendah (0,16). Konfigurasi *hybrid* 70/30 menghasilkan *context relevance* tertinggi (0,34), diikuti *hybrid* 50/50 (0,32). Bobot 70% pada *dense* retrieval berarti sistem lebih mengandalkan pemahaman semantik, namun komponen BM25 sebesar 30% tetap membantu ketika kontrak mengutip nomor regulasi atau istilah teknis secara eksak. Rendahnya skor *sparse* menegaskan bahwa teks kontrak sering menggunakan parafrase dan penulisan yang berbeda dari teks regulasi resmi, sehingga pencocokan kata kunci BM25 saja tidak memadai.

Pada *pipeline* analisis entitas, polanya berbeda: *hybrid* 50/50 menghasilkan nilai tertinggi (0,15), diikuti *hybrid* 30/70 (0,14), sementara *dense* murni justru paling rendah (0,04) bahkan di bawah *sparse* (0,08). Hal ini menunjukkan bahwa pada *query* berupa ringkasan naratif entitas, komponen *sparse* memiliki kontribusi yang lebih besar dibandingkan pada pipeline kepatuhan, kemungkinan karena ringkasan entitas memuat nilai-nilai konkret (nominal, nomor, tanggal) yang lebih efektif dicocokkan secara leksikal. Meskipun demikian, nilai absolut pada pipeline

entitas tetap rendah di seluruh konfigurasi, menegaskan kembali bahwa *query* ringkasan naratif singkat merupakan tantangan tersendiri bagi tahap retrieval.

Berdasarkan hasil ini, *hybrid* 70/30 dipilih sebagai konfigurasi *retrieval* yang direkomendasikan untuk *pipeline* kepatuhan, sedangkan *hybrid* 50/50 menjadi konfigurasi terbaik untuk *pipeline* entitas.

IV.5 Eksperimen Reranking

Eksperimen ini bertujuan mengevaluasi apakah penerapan *reranking* dengan *cross-encoder* dapat meningkatkan relevansi konteks yang diambil untuk kedua *pipeline*. *Reranker* yang digunakan adalah *BGE-reranker-v2-M3*.

IV.5.1 Konfigurasi Eksperimen

Variabel yang dikontrol:

- *retrieval mode* = *hybrid* (50/50)
- *chunk type* = *fixed*
- *top_k* = 10

Reranking menggunakan *fetch_multiplier* = 4, artinya 40 kandidat awal diambil sebelum disortir ulang menjadi 10 *chunk* final. Latensi yang diukur hanya mencakup tahap *retrieve*, tidak termasuk loading model.

Tabel IV.7 Konfigurasi Eksperimen Reranking

Konfigurasi	Deskripsi
Tanpa <i>reranking</i>	10 <i>chunk</i> diambil langsung dari hasil <i>hybrid retrieval</i>
Dengan <i>reranking</i>	40 kandidat diambil, <i>reranking</i> oleh BGE-reranker-v2-M3, diambil 10 teratas

IV.5.2 Hasil Evaluasi

Berdasarkan pengujian, berikut hasil yang didapatkan.

Tabel IV.8 Hasil Evaluasi Reranking (Mean Context Relevance dan Latensi Retrieval)

Konfigurasi	Analisis Kepatuhan CR	Analisis Entitas CR	Latensi Kepatuhan (s)	Latensi Entitas (s)
Tanpa reranking	0,35	0,15	~0,91	~0,47
Dengan reranking	0,24	0,22	~508,4	~4,24

IV.5.3 Analisis

Reranking menunjukkan pengaruh yang berlawanan arah pada dua *pipeline*. Pada *pipeline* analisis kepatuhan, *reranking* justru menurunkan *context relevance* dari 0,35 menjadi 0,24. Sebaliknya, pada *pipeline* analisis entitas, *reranking* meningkatkan *context relevance* dari 0,15 menjadi 0,22.

Perbedaan arah efek ini dapat dijelaskan dari karakteristik query masing-masing *pipeline*. Pipeline kepatuhan menggunakan teks kontrak penuh sebagai query, teks panjang dengan banyak klausul dan istilah hukum. Retrieval awal berbasis embedding BGE-M3 sudah cukup baik untuk query seperti ini, dan *cross-encoder* yang menilai ulang pasangan tampaknya kesulitan menemukan relevansi yang tepat pada pasangan dengan panjang yang sangat timpang, sehingga menghasilkan peringkat yang lebih buruk. Pipeline entitas, sebaliknya, menggunakan ringkasan naratif yang singkat sebagai query. Retrieval awal pada query singkat ini lemah (0,15), dan *cross-encoder* yang membaca pasangan (ringkasan entitas dan chunk regulasi) secara bersamaan mampu mendeteksi relevansi yang tidak tertangkap oleh *embedding similarity*, sehingga relevansi konteks meningkat.

Trade-off utama adalah latensi, pola yang sangat berbeda muncul antar kedua *pipeline*. Pada *pipeline* entitas, *overhead reranking* relatif kecil: latensi naik dari ~0,47 detik menjadi ~4,24 detik per analisis, karena query ringkasan yang singkat membuat penilaian *cross-encoder* tetap ringan. Pada pipeline kepatuhan, *overhead* sangat besar: latensi melonjak dari ~0,91 detik

menjadi rata-rata ~508 detik per analisis. Hal ini disebabkan oleh *query* berupa teks kontrak penuh yang harus dipasangkan dan diskor terhadap 40 kandidat *chunk* oleh *cross-encoder*, sehingga biaya komputasi membengkak seiring panjang *query*. Selain itu, selama proses *reranking* pada *pipeline* analisis, VRAM dari GPU yang digunakan untuk eksperimen terpantau berada pada penggunaan maksimum. Hal ini menandakan bahwa lamanya proses juga mungkin terkendala oleh keterbatasan perangkat keras. Dengan demikian, *reranking* tidak direkomendasikan untuk *pipeline* kepatuhan karena menurunkan akurasi, menambah latensi dan penggunaan *resource* secara ekstrem, namun *reranking* layak dipertimbangkan untuk *pipeline* entitas karena memberikan peningkatan akurasi dengan *overhead* yang masih dapat diterima.

IV.6 Eksperimen Model

Eksperimen ini bertujuan menentukan konfigurasi LLM yang paling optimal untuk tugas analisis kepatuhan dan analisis entitas dengan mempertimbangkan kualitas analisis sekaligus efisiensi inferensi. Tiga model dibandingkan:

- Gemini 3.1 Flash Lite sebagai model API berkemampuan besar
- Qwen3.5:2B, dijalankan secara lokal melalui Ollama
- Qwen3.5:4B, dijalankan secara lokal melalui Ollama

IV.6.1 Konfigurasi Eksperimen

Variabel yang dikontrol:

- *retrieval mode* = *dense*
- *chunk type* = *fixed*
- *top_k* = 10
- *prompt strategy* = *zero-shot*
- *temperature* = 0.0

Seluruh model menggunakan konfigurasi deterministik (*temperature* 0,0). Ketiga model dibatasi dengan *num_predict* = 8192 token untuk mencegah generasi berlebihan dan juga karena keterbatasan VRAM pada perangkat keras yang digunakan. Latensi Gemini tidak diukur karena

berjalan melalui API eksternal dan bergantung pada kondisi jaringan sehingga tidak relevan jika dibandingkan.

Tabel IV.9 Spesifikasi Model yang Dibandingkan

Model	Tipe	Parameter	Backend
gemini-3.1-flash-lite	<i>Closed-source</i> API	N/A (proprietary)	Google API
qwen3.5:2b	<i>Open-source</i> lokal	~2,3 B	Ollama (GPU)
qwen3.5:4b	<i>Open-source</i> lokal	~4,0 B	Ollama (GPU)

IV.6.2 Hasil Evaluasi

Berdasarkan hasil pengujian, berikut hasil yang didapatkan pada *pipeline* analisis kepatuhan dan *pipeline* analisis entitas.

Tabel IV.10 Hasil Evaluasi Perbandingan Model untuk Pipeline Analisis Kepatuhan

Model	Faithfulness	Response Relevancy	Format Validity	Latensi (s)
gemini-3.1-flash-lite	0,3656	0,5298	1,00	N/A (API)
qwen3.5:2b	0,2283	0,5351	0,17	~65,95
qwen3.5:4b	0,2959	0,5281	0,38	~92,41

Tabel IV.11 Hasil Evaluasi Perbandingan Model untuk Pipeline Analisis Entitas

Model	Faithfulness	Response Relevancy	Format Validity	Latensi (s)
gemini-3.1-flash-lite	0,9025	0,5580	0,96	N/A (API)
qwen3.5:2b	0,6457	0,5285	0,76	~28,91
qwen3.5:4b	0,7030	0,5517	0,64	~53,56

IV.6.3 Analisis

Gemini 3.1 Flash Lite mendominasi pada hampir seluruh metrik kualitas untuk kedua *pipeline*. Keunggulan paling penting terletak pada *format validity*. Pada pipeline kepatuhan, *faithfulness* Gemini mencapai 0,366 sementara Qwen 2B hanya 0,228 dan Qwen 4B 0,296. Pada *pipeline* entitas, jarak ini jauh lebih lebar: Gemini mencapai 0,903 dibandingkan Qwen 4B (0,703) dan Qwen 2B (0,646). *Faithfulness* yang tinggi mengindikasikan analisis Gemini lebih berakar pada konteks regulasi dan dokumen kontrak yang diberikan (minim fabrikasi).

Pada format validity, Gemini mencapai 1,00 pada pipeline kepatuhan dan 0,96 pada pipeline entitas, jauh di atas kedua model lokal. Kegagalan format pada Qwen, terutama Qwen 2B pada pipeline kepatuhan (hanya 0,17), mengindikasikan bahwa model berskala kecil kesulitan mengikuti instruksi JSON yang ketat, terutama ketika skema output memiliki banyak field dan aturan bersyarat (seperti *inconsistency_type* yang hanya boleh terisi saat label inconsistent).

Menariknya, Qwen 4B tidak secara konsisten mengungguli Qwen 2B meski memiliki parameter lebih banyak. Pada *pipeline* entitas, Qwen 4B memang lebih unggul dalam *faithfulness* (0,703 vs 0,646), tetapi *format validity*-nya justru lebih rendah (0,64 vs 0,76). *Response relevancy* ketiga model relatif sebanding di kisaran 0,53–0,56 pada kedua *pipeline*, menunjukkan bahwa metrik ini kurang sensitif terhadap perbedaan kapabilitas model untuk tugas ini.

Ketika diperhatikan lebih jauh, gagalnya model lokal (Qwen 4B dan Qwen 2B) dalam memenuhi *format validity* pada *pipeline* analisis kepatuhan terjadi bukan hanya karena sulitnya memenuhi persyaratan pada *format output*. Berdasarkan pengamatan atas beberapa keluaran dengan *format validity* yang tidak terpenuhi, dapat terlihat bahwa *output* tidak tertutup. Model masih berusaha memberikan hasil analisisnya dan semakin jauh keluaran, semakin buruk juga hasilnya. Ini menandakan bahwa kegagalan bukan disebabkan oleh tidak cukupnya *budget output* yang diberikan, melainkan karena keterbatasan model dalam menganalisis teks yang sangat panjang.

Dari sisi efisiensi, kedua model lokal memerlukan waktu inferensi yang masih bisa diterima. Pada pipeline kepatuhan *latency* Qwen 2B rata-rata ~66 detik dan Qwen 4B ~92 detik per analisis, sementara pada pipeline entitas masing-masing ~29 detik dan ~54 detik. Untuk skenario

deployment, kedua model lokal belum dapat diandalkan karena sistem memerlukan *output* dengan validitas format yang tinggi dan konsisten, yang sejauh ini hanya dipenuhi oleh Gemini.

IV.7 Eksperimen Instruksi (Prompt)

Eksperimen ini bertujuan mengidentifikasi strategi instruksi yang paling efektif untuk memandu LLM dalam menghasilkan analisis yang akurat dan terstruktur. Tiga strategi prompt dibandingkan: zero-shot (instruksi saja), role-prompt (instruksi dengan pemberian peran auditor), dan few-shot (instruksi dengan contoh input-output). Model dikontrol pada Gemini 3.1 Flash Lite karena terbukti menghasilkan output berformat valid pada eksperimen sebelumnya.

IV.7.1 Konfigurasi Eksperimen

Variabel yang dikontrol:

- *model* = Gemini 3.1 Flash Lite
- *retrieval mode* = *dense*
- *chunk source* = *fixed*
- *top_k* = 10

Tiga strategi prompt yang diuji adalah sebagai berikut.

Tabel IV.12 Deskripsi Strategi Prompt

Strategi	Deskripsi
<i>Zero shot</i>	Instruksi tugas dan skema JSON output tanpa contoh atau instruksi peran
<i>Role prompt</i>	Instruksi ditambah dengan penetapan peran eksplisit sebagai "Auditor Kepatuhan Pengadaan Barang/Jasa Pemerintah"
<i>Few shot</i>	Instruksi ditambah dua contoh output temuan

IV.7.2 Hasil Evaluasi

Berdasarkan hasil pengujian, berikut hasil yang didapatkan pada *pipeline* analisis kepatuhan dan *pipeline* analisis entitas.

Tabel IV.13 Hasil Evaluasi Strategi Prompting

Strategi Prompt	Pipeline	Faithfulness	Response Relevancy	Format Validity
<i>Few shot</i>	Kepatuhan	0,4545	0,5338	1,00
<i>Role prompt</i>	Kepatuhan	0,1969	0,5257	1,00
<i>Zero shot</i>	Kepatuhan	0,3664	0,5298	1,00
<i>Few shot</i>	Entitas	0,8939	0,5557	0,84
<i>Role prompt</i>	Entitas	0,8577	0,5543	0,92
<i>Zero shot</i>	Entitas	0,8608	0,5614	0,96

IV.7.3 Analisis

Pada *pipeline* analisis kepatuhan, *few-shot* menghasilkan *faithfulness* tertinggi (0,4545), mengungguli *zero-shot* (0,3664) dan jauh di atas *role-prompt* (0,1969). Pemberian contoh nyata *input-output* tampaknya membantu model mengkalibrasi gaya analisis yang diharapkan, sedangkan penetapan *role* saja tanpa contoh justru menurunkan *faithfulness* secara tajam pada *pipeline* ini. Ketiga strategi mempertahankan *format validity* sempurna (1,00), dan perbedaan *response relevancy* antar strategi sangat kecil (kisaran 0,526–0,534), mengindikasikan bahwa relevansi jawaban relatif stabil terlepas dari strategi *prompt*.

Pada *pipeline* analisis entitas, *few-shot* kembali menghasilkan *faithfulness* tertinggi (0,8939), namun dengan *trade-off* pada *format validity* yang turun menjadi 0,84, paling rendah di antara ketiga strategi. Sebaliknya, *zero-shot* menghasilkan *faithfulness* yang hanya sedikit lebih rendah (0,8608) namun mempertahankan *format validity* tertinggi (0,96). *Role-prompt* berada di tengah pada kedua metrik (*faithfulness* 0,8577, *format validity* 0,92). Pemberian contoh pada *few-shot* tampaknya membingungkan model dalam mengikuti format *output* yang ketat untuk *pipeline*

entitas yang memiliki dua sub-kategori temuan berbeda (*entity_issues* dan *entity_compliance_issues*).

Temuan ini konsisten dengan hasil eksperimen model (IV.6) yang menunjukkan Gemini sudah sangat mampu mengikuti instruksi format JSON tanpa contoh. Penambahan contoh pada *few-shot* memberikan manfaat *faithfulness* namun berpotensi menciptakan ambiguitas format ketika struktur output kompleks. Untuk keseimbangan antara kualitas analisis dan konsistensi format, *few-shot* menjadi pilihan terbaik pada pipeline kepatuhan, sedangkan *zero-shot* dengan instruksi yang sangat eksplisit merupakan pilihan paling andal untuk pipeline entitas.

BAB V KESIMPULAN DAN SARAN

Bab ini memaparkan kesimpulan yang diperoleh berdasarkan perancangan, implementasi, dan evaluasi sistem yang dikembangkan dalam penelitian ini. Kesimpulan dihubungkan langsung dengan rumusan masalah yang telah ditetapkan pada Bab I. Pada bab ini juga disertakan saran untuk pengembangan lebih lanjut.

V.1 Kesimpulan

Berikut adalah kesimpulan yang diperoleh setelah proses pengerjaan tugas akhir berdasarkan rumusan masalah yang telah ditetapkan.

1. Sistem deteksi inkonsistensi entitas berhasil dibangun dengan mengimplementasikan pipeline analisis entitas berbasis LLM yang mampu mengidentifikasi empat kategori inkonsistensi secara otomatis: nilai moneter, identitas, temporal, dan kategori lain. Pipeline ini menggunakan mekanisme merangkum entitas oleh LLM menjadi narasi sebelum retrieval regulasi, memungkinkan sistem untuk menganalisis ketidaksesuaian data entitas sekaligus kepatuhan terhadap regulasi yang relevan dengan entitas tersebut.
2. Sistem analisis kepatuhan berbasis RAG berhasil dibangun dengan mengimplementasikan *pipeline* yang mampu mengambil *chunk* regulasi yang relevan dan menghasilkan temuan terstruktur yang menyertakan sitasi ke pasal regulasi. Diberikan juga sitasi ke *chunk* regulasi pada setiap temuan memberikannya elemen *explainability* yang memungkinkan auditor memverifikasi dasar hukum setiap kesimpulan.
3. Berdasarkan serangkaian eksperimen komparatif, didapatkan konfigurasi terbaik untuk masing-masing pipeline adalah sebagai berikut.
 - Untuk pipeline analisis kepatuhan: chunking fixed-size, retrieval hybrid 70:30 (dense:sparse) tanpa reranking, model Gemini 3.1 Flash Lite, dan strategi prompt few-shot.

- Untuk pipeline analisis entitas: chunking semantic, retrieval hybrid 50:50 dengan *reranking*, model Gemini 3.1 Flash Lite, dan strategi prompt zero-shot.

V.2 Saran

Berikut adalah saran yang dapat dipertimbangkan untuk pengembangan lebih lanjut.

1. Evaluasi sistem pada penelitian ini menggunakan dataset uji sebanyak 30 dokumen kontrak publik yang diperoleh dari sejumlah instansi pemerintah. Penelitian selanjutnya dapat memperbesar jumlah dan ragam dokumen kontrak yang digunakan sebagai data benchmark, mencakup variasi jenis pengadaan (barang, pekerjaan konstruksi, jasa konsultansi, dan jasa lainnya), rentang nilai kontrak yang lebih luas, serta variasi format dokumen dari lebih banyak instansi. Dataset uji yang lebih besar dan beragam akan meningkatkan validitas statistik hasil evaluasi serta memberikan gambaran yang lebih representatif mengenai kinerja sistem pada kondisi nyata yang lebih bervariasi.
2. Eksperimen ukuran LLM dalam penelitian ini hanya membandingkan dua varian Qwen3.5 (2B dan 4B) karena keterbatasan perangkat keras. Penelitian selanjutnya dapat mengeksplorasi model *open-source* berukuran lebih besar (misalnya Qwen3.5:27B) yang dijalankan secara lokal, untuk mengetahui pada skala parameter berapa kualitas analisis mulai mendekati model API. Ini relevan untuk skenario *deployment* yang memerlukan privasi data penuh.
3. Sistem yang dikembangkan telah menyediakan struktur relasi antarregulasi pada basis data, tetapi belum mampu menerapkan perubahan (amendemen) regulasi secara otomatis untuk menghasilkan versi peraturan yang terkonsolidasi. Penelitian selanjutnya dapat mengembangkan mekanisme *parsing* struktural pada tingkat pasal dan ayat yang disertai pemahaman semantik atas kalimat perubahan, sehingga sistem dapat membedakan ayat asli dari ayat hasil penulisan ulang pasal, serta menangani ketentuan yang tidak tertulis dalam struktur pasal-ayat yang baku (misalnya ketentuan pada lampiran atau pedoman pelaksanaan). Kemampuan ini akan memungkinkan

sistem untuk selalu merujuk pada ketentuan yang termutakhir dan menghindari pengambilan pasal yang sebenarnya telah diubah atau dicabut.

REFERENSI

- Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2024). Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection (arXiv:2310.11511). arXiv. <http://arxiv.org/abs/2310.11511>
- Anthropic. (2024, September 19). Contextual retrieval. <https://www.anthropic.com/news/contextual-retrieval>
- Badan Pengawasan Keuangan dan Pembangunan. (2019). Peraturan Badan Pengawasan Keuangan dan Pembangunan Nomor 3 Tahun 2019 tentang Pedoman Pengawasan Intern atas Pengadaan Barang/Jasa Pemerintah. BPKP.
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language Models are Few-Shot Learners (arXiv:2005.14165). arXiv. <http://arxiv.org/abs/2005.14165>
- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. doi:10.48550/arXiv.2402.03216 <https://doi.org/10.48550/arXiv.2402.03216>
- Cormack, G. V., Clarke, C. L., & Buettcher, S. (2009). Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. ACM. <https://doi.org/10.1145/1571941.1572114>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding (arXiv:1810.04805). arXiv. <http://arxiv.org/abs/1810.04805>
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). RAGAS: Automated Evaluation of Retrieval Augmented Generation (arXiv:2309.15217). arXiv. <http://arxiv.org/abs/2309.15217>
- Gao, L., Ma, X., Lin, J., & Callan, J. (2022). Precise Zero-Shot Dense Retrieval without Relevance Labels (arXiv:2212.10496). arXiv. <http://arxiv.org/abs/2212.10496>

- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... & Wang, H. (2023). Retrieval-Augmented Generation for Large Language Models: A Survey (arXiv:2312.10997). arXiv. <http://arxiv.org/abs/2312.10997>
- Guha, N., Nyarko, J., Ho, D. E., Ré, C., Chilton, A., Narayana, A., ... Li, Z. (2023). LegalBench: A collaboratively built benchmark for measuring legal reasoning in large language models. doi:10.48550/arXiv.2308.11462
- Günther, M., Mohr, I., Williams, D.J., Wang, B., & Xiao, H. (2024). Late Chunking: Contextual Chunk Embeddings Using Long-Context Embedding Models (arXiv:2409.04701). arXiv. <http://arxiv.org/abs/2409.04701>
- Hendrycks, D., Burns, C., Chen, A., & Ball, S. (2021). CUAD: An Expert-Annotated NLP Dataset for Legal Contract Review (arXiv:2103.06268). arXiv. <http://arxiv.org/abs/2103.06268>
- Järvelin, K., & Kekäläinen, J. (2002). Cumulated Gain-Based Evaluation of IR Techniques. ACM Transactions on Information Systems (TOIS), 20(4). ACM. <https://doi.org/10.1145/582415.582418>
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), 1–38. <https://doi.org/10.1145/3571730>
- Jiang, C., & Yang, X. (2023). Legal Syllogism Prompting: Teaching Large Language Models for Legal Judgment Prediction. Proceedings of the Nineteenth International Conference on Artificial Intelligence and Law (arXiv:2307.08321). arXiv. <https://arxiv.org/abs/2307.08321>
- Jurafsky, D., & Martin, J. H. (2025). Speech and Language Processing (3rd ed. draft). <https://web.stanford.edu/~jurafsky/slp3/>
- Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., ... & Yih, W. T. (2020). Dense Passage Retrieval for Open-Domain Question Answering. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). Association for Computational Linguistics. <https://aclanthology.org/2020.emnlp-main.550/>
- Katz, D. M., Bommarito, M. J., Gao, S., & Arredondo, P. (2024). GPT-4 Passes the Bar Exam. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 382(2270). The Royal Society. <https://doi.org/10.1098/rsta.2023.0254>

- Khot, T., Trivedi, H., Finlayson, M., Fu, Y., Richardson, K., Clark, P., & Sabharwal, A. (2022). Decomposed Prompting: A Modular Approach for Solving Complex Tasks (arXiv:2210.02406). arXiv. <http://arxiv.org/abs/2210.02406>
- Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., & Iwasawa, Y. (2022). Large Language Models are Zero-Shot Reasoners. *Advances in Neural Information Processing Systems*, 35. https://proceedings.neurips.cc/paper_files/paper/2022/hash/8bb0d291acd4acf06ef112099c16f326-Abstract-Conference.html
- Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., ... & Zettlemoyer, L. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics. <https://aclanthology.org/2020.acl-main.703/>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>
- Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2023). Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 12. MIT Press. https://doi.org/10.1162/tac1_a_00638
- Liu, P., Yuan, W., Fu, J., Jiang, Z., Hayashi, H., & Neubig, G. (2023). Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing. *ACM Computing Surveys*, 55(9). ACM. <https://doi.org/10.1145/3560815>
- Merola, C., & Singh, J. (2025). Reconstructing Context: Evaluating Advanced Chunking Strategies for Retrieval-Augmented Generation (arXiv:2504.19754). arXiv. <http://arxiv.org/abs/2504.19754>
- Nogueira, R., & Cho, K. (2019). Passage re-ranking with BERT (arXiv:1901.04085). arXiv. <http://arxiv.org/abs/1901.04085>
- Olsson, C., Elhage, N., Nanda, N., Joseph, N., DasSarma, N., Henighan, T., ... & Olah, C. (2022). In-context Learning and Induction Heads. *Transformer Circuits Thread*. <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/index.html>

- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., ... & Lowe, R. (2022). Training Language Models to Follow Instructions with Human Feedback. *Advances in Neural Information Processing Systems*, 35. https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html
- Pipitone, N., & Alami, G. H. (2024). LegalBench-RAG: A Benchmark for Retrieval-Augmented Generation in the Legal Domain (arXiv:2408.10343). arXiv. <http://arxiv.org/abs/2408.10343>
- Radbruch, G. (1950). *Legal Philosophy* (K. Wilk, Trans.). Harvard University Press.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. (2019). Language Models are Unsupervised Multitask Learners. OpenAI. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf
- Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., ... & Liu, P. J. (2020). Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. *The Journal of Machine Learning Research*, 21(1). JMLR. <https://jmlr.org/papers/v21/20-074.html>
- Rahardjo, S. (2009). *Hukum dan Perilaku*. Penerbit Buku Kompas.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks (arXiv:1908.10084). arXiv. <http://arxiv.org/abs/1908.10084>
- Reynolds, L., & McDonell, K. (2021). Prompt Programming for Large Language Models: Beyond the Few-Shot Paradigm. *Proceedings of the CHI Conference on Human Factors in Computing Systems*. ACM. <https://dl.acm.org/doi/10.1145/3411763.3451760>
- Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends® in Information Retrieval*, 3(4). Now Publishers. <https://doi.org/10.1561/15000000019>
- Sanjaya, B. A., & Sulistyono, S. (2015). Big Data: Inkonsistensi Data dan Solusinya. *Seminar Nasional Teknologi Informasi dan Multimedia 2015*. STMIK AMIKOM Yogyakarta. <https://ojs.amikom.ac.id/index.php/semnasteknomedia/article/viewFile/822/788>
- Sturua, S., Mohr, I., Akram, M. K., Günther, M., Wang, B., Krimmel, M., Wang, F., Mastrapas, G., Koukounas, A., Wang, N., & Xiao, H. (2024). jina-embeddings-v3: Multilingual embeddings with task LoRA (arXiv:2409.10173). arXiv. <http://arxiv.org/abs/2409.10173>

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30. <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., ... & Zhou, D. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems*, 35. https://proceedings.neurips.cc/paper_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html
- White, J., Fu, Q., Hays, S., Sandborn, M., Olea, C., Gilbert, H., ... & Schmidt, D. C. (2023). A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT (arXiv:2302.11382). arXiv. <http://arxiv.org/abs/2302.11382>